INTELIGENŢĂ ARTIFICIALĂ

Sisteme inteligente

Sisteme care învață singure

- generative AI-

Laura Dioşan

Sumar

A. Scurtă introducere în Inteligența Artificială (IA)

c. Sisteme inteligente

- Sisteme care învaţă singure
 - Arbori de decizie
 - Reţele neuronale artificiale
 - kNN
 - Algoritmi evolutivi
 - Maşini cu suport vectorial
- Sisteme bazate pe reguli
- Sisteme hibride
- B. Rezolvarea problemelor prin căutare
 - Definirea problemelor de căutare
 - Strategii de căutare
 - Strategii de căutare neinformate
 - Strategii de căutare informate
 - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
 - Strategii de căutare adversială

Rețele neuronale artificiale

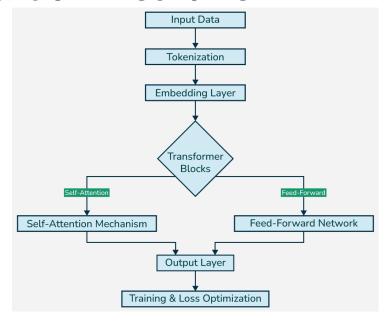
■ Rețele neuronale dense (fully-connected)

■ Rețele neuronale convolutive

Transformers

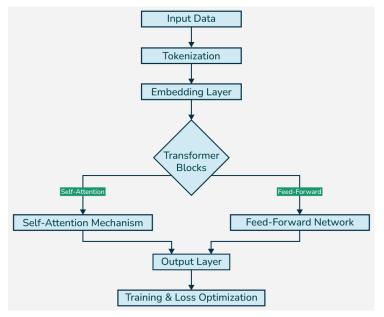
Procesarea textelor/limbajelor

- Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network



Procesarea textelor/limbajelor

- □ Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network



94 382

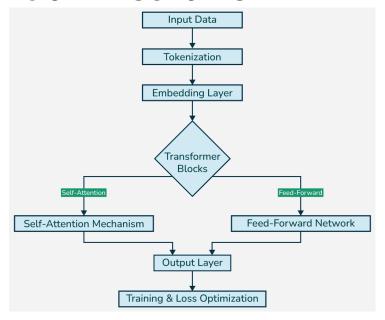
We're no strangers to love
You know the Tucks and so dd I (dd II
A full Commitment's shat I'm thinking
You wouldn't port this from any other.
I just manna tell you how I'm feeling
onts make you understand
Hewer gonne Ist you down
Hewer gonne Ist you down
Hewer gonne Ist you down
Hewer gonne make you cry
Hewer gonne make you cry
Hewer gonne sake you cry
Hewer gonne set la sike and burt you

Tokenisation

- Token-based models
 - White Space: Splits on spaces (simple but limited)
 - Word: Breaks into words (common for English)
 - Sentence: Divides text into sentences
 - Character: Splits into individual characters
 - N-gram: Creates sequences of n items/elements
 - fastText (2016)
 - subword: Breaks words into smaller parts
 - Byte Pair Encoding (2016): Merges common character pairs → GPT, GPT2, GPT3
 - WordPiece (2012): Google's method for balancing words and subwords → BERT
 - Unigram (2018) → T5, AIBERT
- Token-free models
 - CharFormer
 - ByT5
 - MegaByte (2023)
 - Byte-latent transformer (2024)
- Useful resources
 - 07_tokenizers.ipynb
 - Karpathy's tutorial https://www.youtube.com/watch?v=zduSFxRajkE
 - Hugging Face tutorial https://huggingface.co/learn/llm-course/en/chapter2/4

Procesarea textelor/limbajelor

- Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network



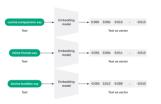


- Word Embeddings
 - Frequency-based embeddings
 - One-hot encoding
 - TF-IDF
 - Co-occurrence matrix
 - Prediction based embeddings → Word / subword embeddings
 - De ce?
 - Token → reprezentari dense
 - Cum?
 - Word2vec (Skip-gram or Continuous Bag of Words (CBOW), FastText, GloVe, altele



Word Embeddings

- Vectori rari vs. vectori densi
 - □ Vectorii clasici → matricea de aparitie/co-ocurenta a termenilor
 - lungi (length |V|= 20,000 -> 50,000)
 - rari (f multe elemente sunt 0)
 - Alternativa: vectori invatati (prin AI/ML)
 - scurti (length 200-1000)
 - densi (multe elemente nu sunt 0)
 - De ce vectori densi?
 - Vectorii scurti -> folositi mai usor ca si features in algoritmii de invatare (mai putini coeficienti de invatat)
 - Vectorii densi pot generaliza mai bine, captand sinonimia termenilor
 - Bike scooter
 - Car automobile
 - House apartment



- Word Embeddings
 - Learnt embeddings
 - Static (context-free)

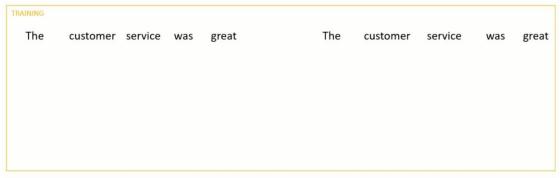


- Word Embeddings
 - Learnt embeddings
 - Static (context-free)
 - Word2vec (2013)
 - GLoVe (2014)





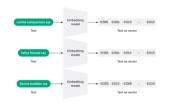
- Word Embeddings
 - Learnt embeddings
 - Static (context-free)
 - Word2vec (2013)
 - GLoVe (2014)
 - Dinamic (context-based)
 - ELMo (2018)





- Word Embeddings
 - Learnt embeddings
 - Static (context-free)
 - Word2vec (2013)
 - GLoVe (2014)
 - Dinamic (context-based)
 - ELMo (2018)
 - BERT (2019)

[CLS] The _____ service was great [SEP] They ____ very help ##ful [SEP]

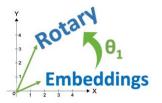


Word Embeddings

- Learnt embeddings
 - Static (context-free)
 - Word2vec (2013)
 - GLoVe (2014)
 - Dinamic (context-based)
 - ELMo (2018)
 - BERT (2019)
- Great resources
 - Word Embeddings https://lena-voita.github.io/nlp_course/word_embeddings.html
 - The Illustrated Word2vec Jay Alammar Visualizing machine learning one concept at a time https://jalammar.github.io/illustrated-word2vec/



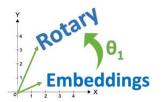
- Word Embeddings
 - Frequency-based embeddings
 - One-hot encoding
 - TF-IDF
 - Co-occurrence matrix
 - Prediction based embeddings → Word / subword embeddings
 - De ce?
 - Token → reprezentari dense
 - Cum?
 - Word2vec (Skip-gram or Continuous Bag of Words (CBOW), FastText, GloVe, altele
 - Positional embeddings



Word Embeddings

- Positional embeddings
 - Ce valori conţine PE?
 - Principii
 - Embedding-urile trebuie sa păstreze distanța originală între cuvinte
 - dist(Emb(câine),Emb(pisică)) < dist(Emb(câine),Emb(fereastră))
 - Dist(Emb(word_k),Emb(word_{k+1}))=Dist(Emb(word_p),Emb(word_{p+1}))
 - Ortogonalitate Embedding-urile cuvintelor ne-conectate să fie perpendiculare
 - Emb(uṣă) ⊥ Emb(peṣte)
 - Similaritate (uṣă, peṣte) = 0
 - Embedding-uri independente de lungimea propoziției
 - → putere de generalizare (train vs. test)
 - → bounded
 - Reprezentări / valori posibile
 - Poziția efectivă (1,2,3,4)
 - Poziția în reprezentare 1-hot encoding
 - Poziția în reprezentare binară
 - Poziția în reprezentare polară

Pozitia in propozitie



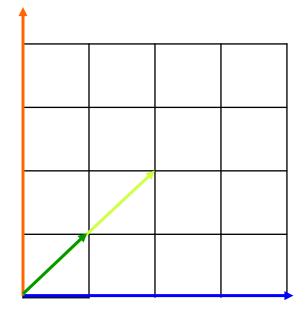
Exemplu

- O propoziție cu 5 cuvinte și d = 1
- PE(cuv) = poziția cuvântului

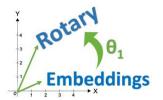
0
1
2
3
4

Dist	w0	w1	w2	w3	w4
w0	0	1	2	3	4
w1	1	0	1	2	3
w2	2	1	0	1	2
w3	3	2	1	0	1
w4	4	3	2	1	0





Pozitia normalizată in propozitie



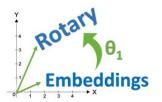
Exemplu

- O propoziție cu 5 cuvinte și d = 1
- PE(cuv) = poziția cuvântului

0/5
1/5
2/5
3/5
4/5

 Problema: al k-lea cuvânt într-o propozției de N cuvinte are alt embedding decât al k-lea cuvânt într-o propoziție cu M cuvinte

1-hot encoding



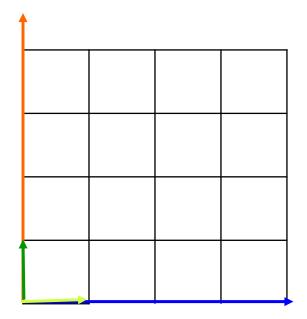
Exemplu

- O propoziție cu 5 cuvinte și d = 6
- PE(cuv) = reprezentarea 1-hot a poziției cuvântului

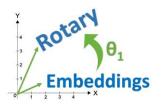
0	0	0	0	0	1
0	0	0	0	1	0
0	0	0	1	0	0
0	0	1	0	0	0
0	1	0	0	0	0

Dist	w0	w1	w2	w3	w4
w0	0	1.4	1.4	1.4	1.4
w1	1.4	0	1.4	1.4	1.4
w2	1.4	1.4	0	1.4	1.4
w3	1.4	1.4	1.4	0	1.4
w4	1.4	1.4	1.4	1.4	0

sim(PE(wi), PE(wj))=1.4, orice $i \neq j$



Binary encoding



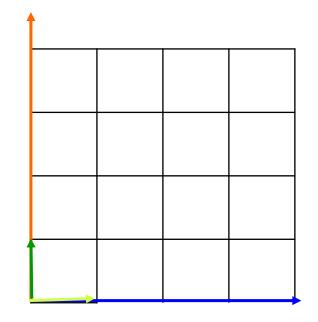
Exemplu

- O propoziție cu 5 cuvinte și d = 6
- PE(cuv) = reprezentarea binară a poziției cuvântului

0	0	0	0	0	0
0	0	0	0	0	1
0	0	0	0	1	0
0	0	0	0	1	1
0	0	0	1	0	0

Dist	w0	w1	w2	w3	w4
w0	0	1	1	√2	1
w1	1	0	√2	1	√2
w2	1	√2	0	1	√2
w3	√2	1	1	0	√3
w4	1	√2	√2	√3	0

exista i, j a.î. sim(PE(wi), PE(wj))=0



Problema: dist nu e functie monotona!

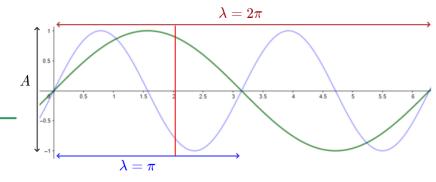
Sin-based encoding (Rotary Pc4

Exemplu

- O propoziție cu 5 cuvinte și d = 6
- PE(cuv) = valorile functiei sin pentru diferite argumente (frecvențe sau lungimi de undă)
 - \square E.g. Sin(2 π pos / λ_i), i =0,1,2,..,d-1

pos	_	$\lambda = \pi$	$\lambda = 2\pi$	$\lambda = 3\pi$	$\lambda = 4\pi$	$\lambda = 5\pi$	λ= 6π
0	\rightarrow	sin(2*0)	sin(0)	sin(2/3*0)	sin(2/4*0)	sin(2/5*0)	sin(2/6*0)
1	\rightarrow	sin(2*1)	sin(1)	sin(2/3*1)	sin(2/4*1)	sin(2/5*1)	sin(2/6*1)
2	\rightarrow	sin(2*2)	sin(2)	sin(2/3*2)	sin(2/4*2)	sin(2/5*2)	sin(2/6*2)
3	\rightarrow	sin(2*3)	sin(3)	sin(2/3*3)	sin(2/4*3)	sin(2/5*3)	sin(2/6*3)
4	\rightarrow	sin(2*4)	sin(4)	sin(2/3*4)	sin(2/4*4)	sin(2/5*4)	sin(2/6*4)

Sin-based encoding



Exemplu

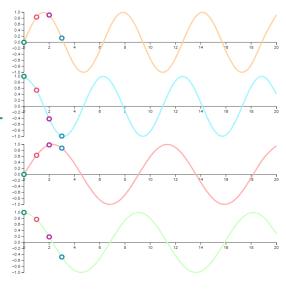
- O propoziție cu 5 cuvinte și d = 6
- PE(cuv) = valorile functiei sin pentru diferite argumente (frecvențe sau lungimi de undă)
 - E.g. Sin(2 π pos / λ_i), i =0,1,2,...,d-1

pos		$\lambda = \pi$	$\lambda = 2\pi$	$\lambda = 3\pi$	$\lambda = 4\pi$	$\lambda = 5\pi$	$\lambda = 6\pi$
0	\rightarrow	sin(0)	sin(0)	sin(0)	sin(0)	sin(0)	sin(0)
1	\rightarrow	sin(2*1)	sin(1)	sin(2/3*1)	sin(2/4*1)	sin(2/5*1)	sin(2/6*1)
2	\rightarrow	sin(2*2)	sin(2)	sin(2/3*2)	sin(2/4*2)	sin(2/5*2)	sin(2/6*2)
3	\rightarrow	sin(2*3)	sin(3)	sin(2/3*3)	sin(2/4*3)	sin(2/5*3)	sin(2/6*3)
4	\rightarrow	sin(2*4)	sin(4)	sin(2/3*4)	sin(2/4*4)	sin(2/5*4)	sin(2/6*4)

 $sim(PE(word_0), PE(word_k)) = 0!!!$

Sin&cos-based encoding

Exemplu



- O propoziție cu 5 cuvinte și d = 6
- PE(cuv) = perechi (sin, cos) pentru diferite argumente (frecvențe sau lungimi de undă)
 - E.g. $(\sin(pos/10000^{2i/d}), \cos(pos/10000^{2i/d})), i = 0,1,2,..,d-1$

pos		i=0	i=1	i=2	i=3	i=4	i=5
0	\rightarrow	sin(0)	cos(0)	sin(0)	cos(0)	sin(0)	cos(0)
1	\rightarrow	sin(1)	cos(1)	sin(1/10000 ^{4/6})	cos(1/10000 ^{4/6})	sin(1/10000 ^{8/6})	cos(1/10000 ^{8/6})
2	\rightarrow	sin(2)	cos(2)	sin(2/10000 ^{4/6})	cos(2/10000 ^{4/6})	sin(2/10000 ^{8/6})	cos(2/10000 ^{8/6})
3	\rightarrow	sin(3)	cos(3)	sin(3/10000 ^{4/6})	cos(3/10000 ^{4/6})	sin(3/10000 ^{8/6})	cos(3/10000 ^{8/6})
4	\rightarrow	sin(4)	cos(4)	sin(4/10000 ^{4/6})	cos(4/10000 ^{4/6})	sin(4/10000 ^{8/6})	cos(4/10000 ^{8/6})

Sin&cos-based encoding

Resources

- https://towardsdatascience.com/why-and-howto-achieve-longer-context-windows-for-llms-5f76f8656ea9/
- https://aiexpjourney.substack.com/p/an-indepth-exploration-of-rotary-position-embeddingrope-ac351a45c794
- https://kazemnejad.com/blog/transformer_archit ecture_positional_encoding/

Positional embedding

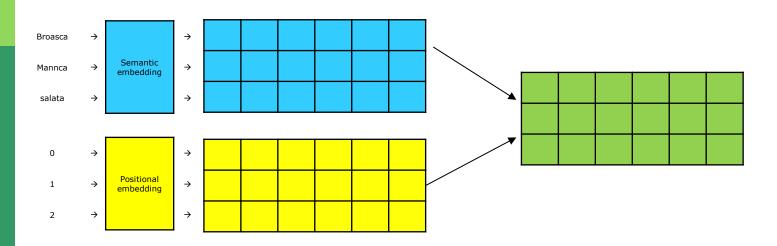
□ Cuvinte → Embeddings

- Pentru o propoziție cu n cuvinte, se obțin n embedding-uri (de lungime d)
 - Care țin cont de semantica cuvintelor
 - Word Embeddings
 - descoperite / învățate
 - prin ML (Word2Vec, GloVe, etc.)
 - Care țin cont de poziția (absolută sau relativă) a cuvintelor în propoziției
 - Positional Emebeddings
 - calculate

Positional embedding

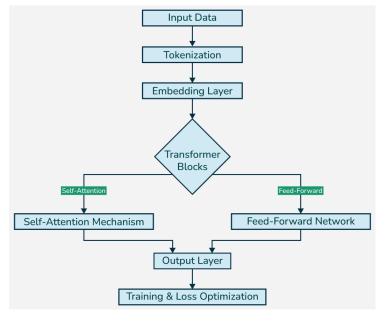
Exemplu

- O propoziție cu n cuvinte
- Fiecărui cuvânt i se asociază
 - Un embedding semantic SE de lungime d
 - Un embedding pozițional PE de lungime d
 - □ Embedding-ul final corespunzător cuvântului va fi suma celor 2 (WE + PE) → n x d valori



Procesarea textelor/limbajelor

- Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network



flamanda

Broasca a mancat salata pentru ca ea era ...

delicioasa





În acvariu era o **broască** și un pește

S-a stricat **broasca** de la ușă

Remember – embeddings

 cuvinte izolate precum: geam, ușă, clanță, pisică, pește, câine, broască

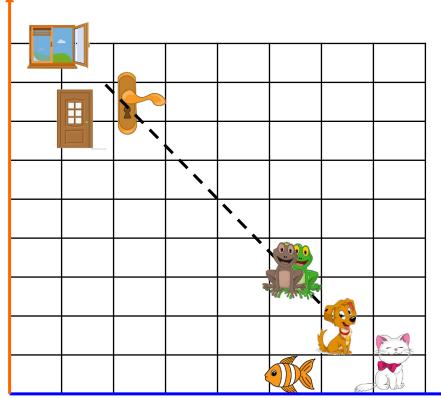
Nivelul tehnologic

Presupunem 2 atribute:

- caracterul animalic
- nivelul tehnologic

Attention

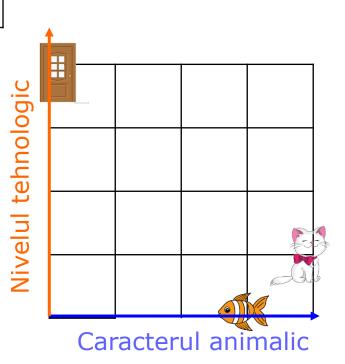
- Contextul e ca un magnet!
- Atrage cuvintele care se potrivesc!



Caracterul animalic

Similaritatea între cuvinte

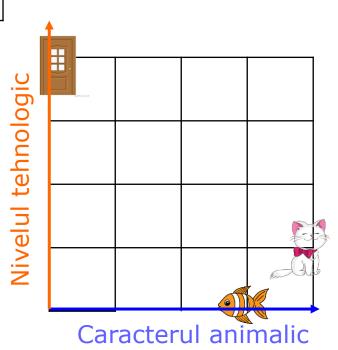
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4



Similaritatea între cuvinte

Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

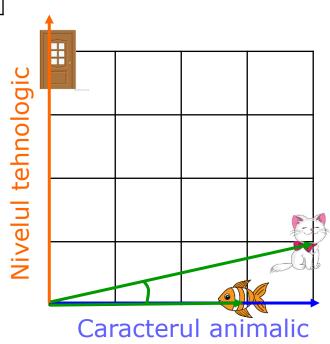
□ sim (pisică, pește) =



Similaritatea între cuvinte

Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

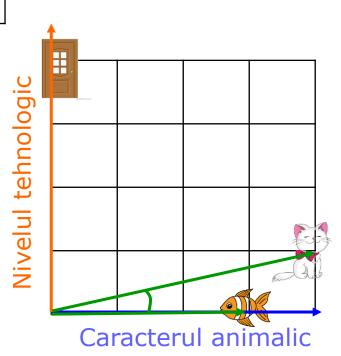
□ sim (pisică, pește) =



Similaritatea între cuvinte

Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

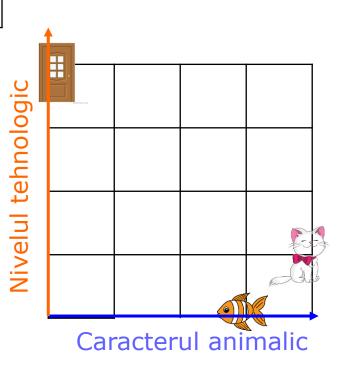
□ sim (pisică, pește) = $sim([4,1], [3,0]) = (4*3 + 1*0)/(\sqrt{17} * \sqrt{9})$ = 12 / (4.12 * 3) = 0.97



Similaritatea între cuvinte

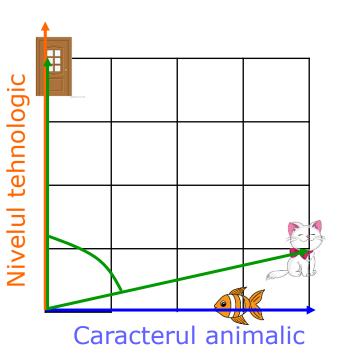
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- sim (pisică, pește) = sim([4,1], [3,0]) = (4*3 + 1*0)/(√17 * √9)= 12/(4.12*3) = 0.97
- □ sim(pisică, ușă) =



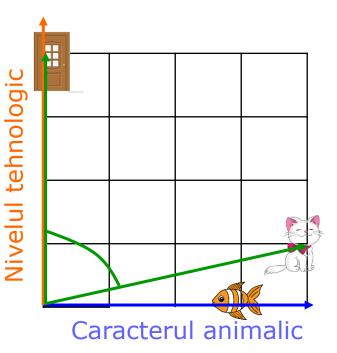
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- sim (pisică, pește) = sim([4,1], [3,0]) = (4*3 + 1*0)/(√17 * √9)= 12/(4.12*3) = 0.97
- □ sim(pisică, ușă) =



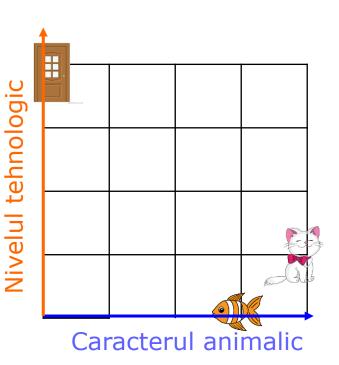
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- sim (pisică, pește) = sim([4,1], [3,0]) = (4*3 + 1*0)/(√17 * √9)= 12/(4.12*3) = 0.97
- □ sim(pisică, ușă) = sim([4,1],[0,4]) = $(4*0 + 1*4) / (\sqrt{17} * \sqrt{16})$ = 4 / (4.12 * 4) = 0.24



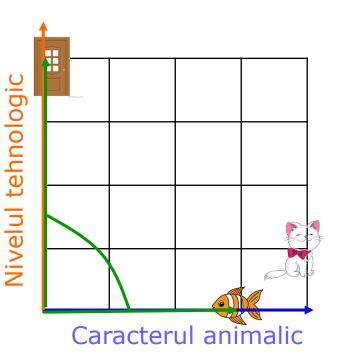
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- □ sim (pisică, pește) = $sim([4,1], [3,0]) = (4*3 + 1*0)/(\sqrt{17} * \sqrt{9})$ = 12 / (4.12 * 3) = 0.97
- □ sim(pisică, ușă) = sim([4,1],[0,4]) = $(4*0 + 1*4) / (\sqrt{17} * \sqrt{16})$ = 4 / (4.12 * 4) = 0.24
- □ sim(pește, ușă) =



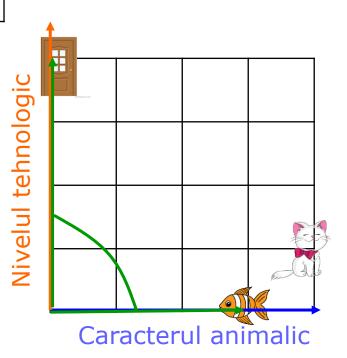
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- sim (pisică, pește) = $sim([4,1], [3,0]) = (4*3 + 1*0)/(\sqrt{17} * \sqrt{9})$ = 12 / (4.12 * 3) = 0.97
- sim(pisică, ușă) = $sim([4,1],[0,4]) = (4*0 + 1*4) / (\sqrt{17} * \sqrt{16})$ = 4 / (4.12 * 4) = 0.24
- □ sim(pește, ușă) =



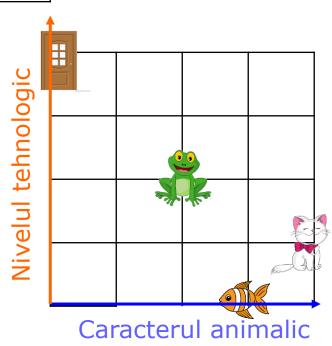
Cuvântul	caracterul animalic	nivelul tehnologic
Pisică	4	1
Pește	3	0
Ușă	0	4

- □ sim (pisică, pește) = $sim([4,1], [3,0]) = (4*3 + 1*0)/(\sqrt{17} * \sqrt{9})$ = 12 / (4.12 * 3) = 0.97
- sim(pisică, ușă) = $sim([4,1],[0,4]) = (4*0 + 1*4) / (\sqrt{17} * \sqrt{16})$ = 4 / (4.12 * 4) = 0.24
- $sim(pește, ușă) = sim([3,0],[0,4]) = (3*0 + 0*4) / (\sqrt{9}* \sqrt{16}) = 0$



- Contextul cuvintelor matricea de afinitate
 - S-a stricat broasca de la ușă

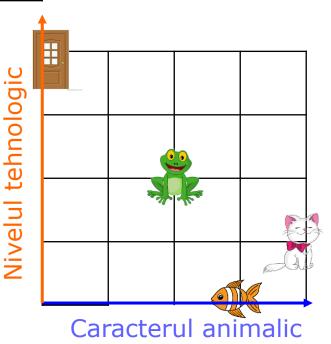
	broască	ușă
broască		
ușă		



- Contextul cuvintelor matricea de afinitate
 - S-a stricat broasca de la ușă

	broască	ușă
broască		
ușă		

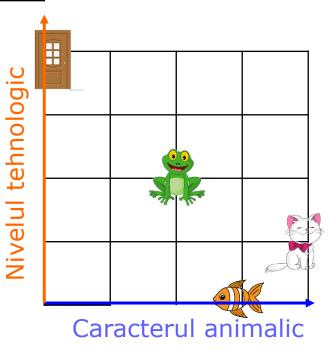
- □ sim(broască, broască) = 1
- □ sim(broască, ușă) = sim([2,2], [0,4]) = $(2*0 + 2*4) / (\sqrt{8} * \sqrt{16}) = 0.7$



- Contextul cuvintelor matricea de afinitate
 - S-a stricat broasca de la ușă

	broască	ușă
broască	1.0	0.7
ușă	0.7	1.0

- □ sim(broască, broască) = 1
- □ sim(broască, ușă) = sim([2,2], [0,4]) = $(2*0 + 2*4) / (\sqrt{8} * \sqrt{16}) = 0.7$



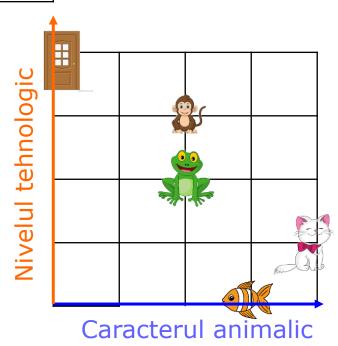
- Contextul cuvintelor matricea de afinitate
 - S-a stricat broasca de la ușă

	broască	ușă
broască	1.0	0.7
ușă	0.7	1.0

□ broască = 1.0 * broască + 0.7 * ușă

- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță

	Broască	Maimuță
Broască		
Maimuță		

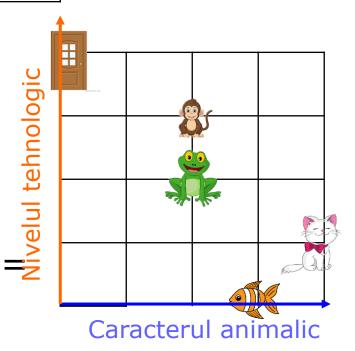


- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță

	Broască	Maimuță
Broască		
Maimuță		

- □ sim(broască, broască) = 1
- □ sim(broască, maimuță) = sim([2,2], [2,3]) = (2*2 + 2*3) / (√8 * √13)

 $12 / \sqrt{2} = 0.9$

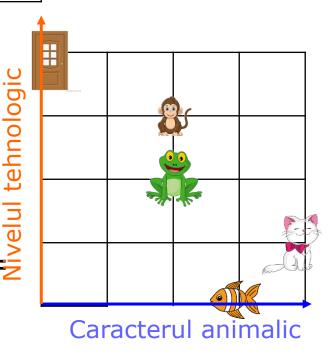


- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță

	Broască	Maimuță
Broască	1.0	0.9
Maimuță	0.9	1.0

- □ sim(broască, broască) = 1
- □ sim(broască, maimuță) = sim([2,2], [2,3]) = $(2*2 + 2*3) / (\sqrt{8} * \sqrt{13})$

 $12 / \sqrt{2} = 0.9$



- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță

	broască Maimuță			
Broască	1.0	0.9		
Maimuță	0.9	1.0		

□ broască = 1.0 * broască + 0.9 * maimuță

- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță
 - S-a stricat broasca de la ușă

```
broască = 1 * broască + 0.9 * maimuță
```

broască = 1 * broască + 0.7 * ușă



Normalizare – de care?

```
broască = ? * broască + ? * maimuță
```

- Contextul cuvintelor matricea de afinitate
 - O broască s-a întâlnit cu o maimuță
 - S-a stricat broasca de la ușă

```
broască = 1 * broască + 0.9 * maimuță
```

broască = 1 * broască + 0.7 * ușă



Normalizare - softmax

```
broască = 0.52 * broască + 0.48 * maimuță
```

Mecanismul de "atentie

- Contextul cuvintel
 - O **broască** s-a în
 - S-a stricat broase

broască = 1 * broas

broască = 1 * broasc



Caracterul animalic

Nivelul tehnologic

broască = 0.52 * broască + 0.48 * maimuță broască = 0.57 * broască + 0.43 * ușă

broască = 0.52 * [2,2] + 0.48 * [2,3]

broască = 0.57 * [2,2] + 0.43 * [0,4]

Mecanismul de "atentiq

- Contextul cuvintelor matri
 - O **broască** s-a întâlnit
 - S-a stricat broasca de

broască = 0.52 * broască + 0.48

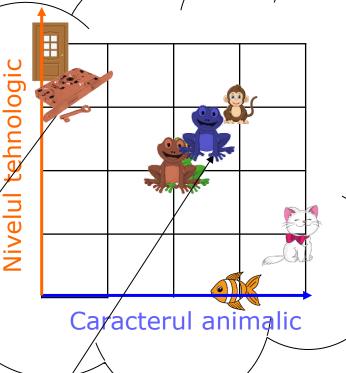
broască = 0.57 * broască + 0.43 * ușă

broască =
$$0.52 * [2,2] + 0.48 * [2,3]$$

broască =
$$0.57 * [2,2] + 0.43 * [0,4]$$

broască \neq [2.00,2.48]

broască = [1.14, 2.86]

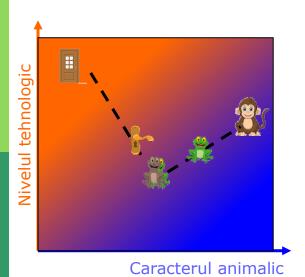


V (Values)

	Broască	Maimuță
Broască	0.52	0.48
Maimuță	0.48	0.52

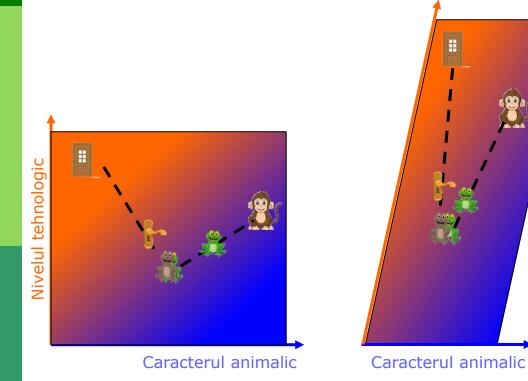
Un alt exemplu:

O **broască** s-a întâlnit cu o maimuță S-a stricat **broasca** de la ușă



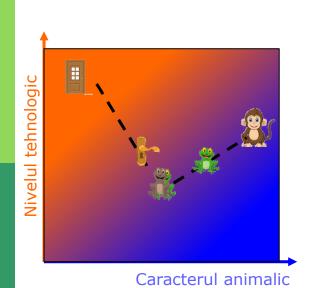
Un alt exemplu:

O **broască** s-a întâlnit cu o maimuță S-a stricat **broasca** de la ușă

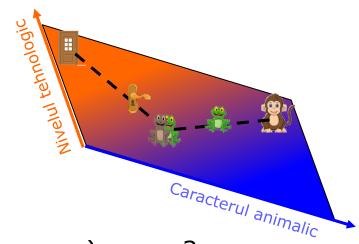


Un alt exemplu:

O **broască** s-a întâlnit cu o maimuță S-a stricat **broasca** de la ușă



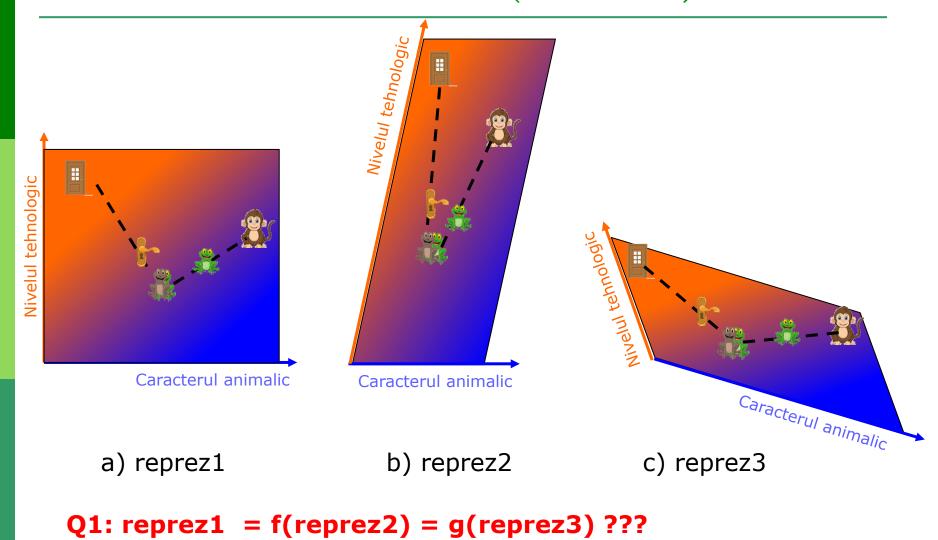
Nivelul tehnologic Caracterul animalic



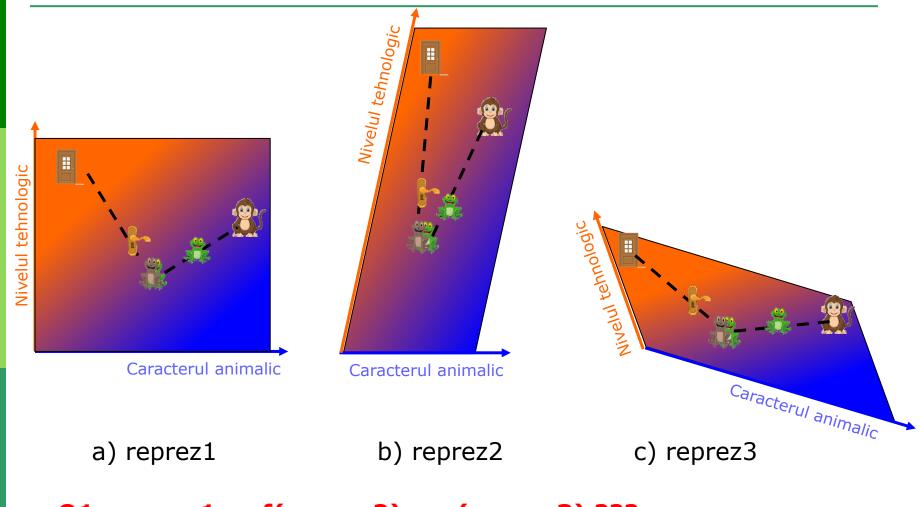
a) reprez1

b) reprez2

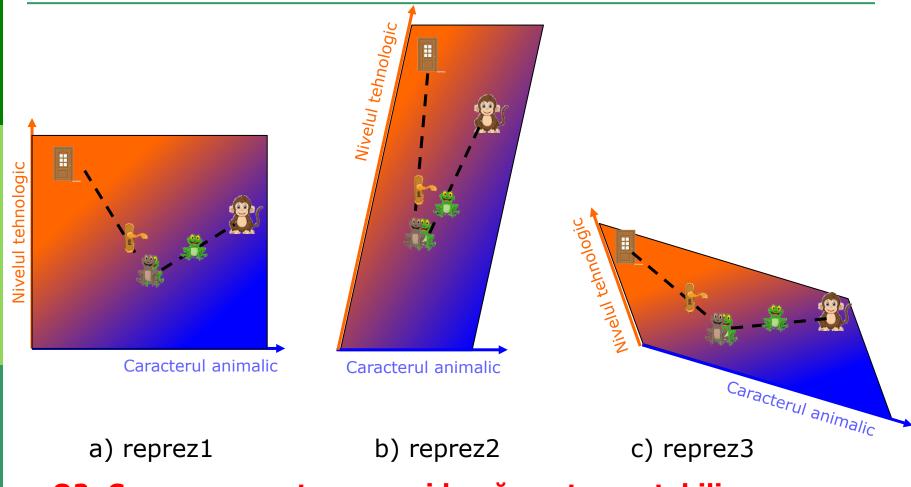
c) reprez3



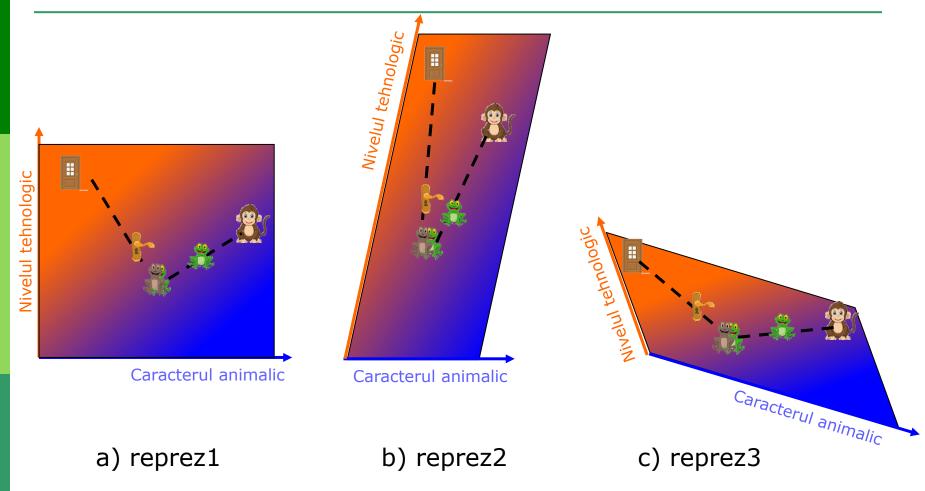
Inteligență artificială - generative AI



Q1: reprez1 = f(reprez2) = g(reprez3) ??? Da!!! Tranformare liniară!!!



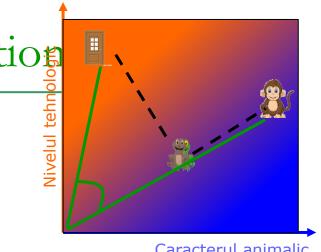
Q2: Care reprezentare e mai bună pentru a stabili similaritatea (deci a face diferența între sensurile lui broască)?



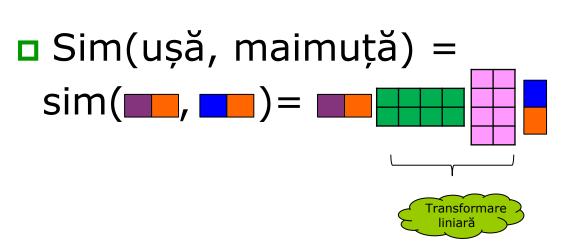
Q2: Care reprezentare e mai bună pentur a stabili similaritatea (deci a face diferența între sensurile lui broască)?

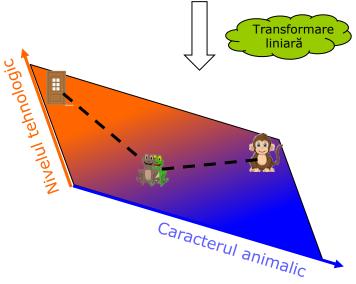
Reprezentarea 1 sau 3!

□ Sim(uṣă, maimuță) = sim(___,__)= ___

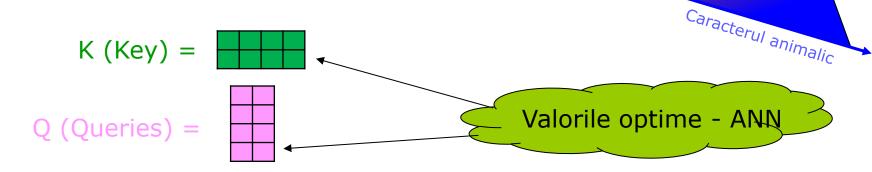


Caracterul animalic





Mecanismul de "atentie" (attention **Nivelul tehno** □ Sim(uṣă, maimuță) = sim(____,___)= [Caracterul animalic **Transformare** □ Sim(uṣă, maimuță) =



Mecanismul de "atentiq

- Contextul cuvintel
 - O **broască** s-a în
 - S-a stricat broase

broască = 1 * broas

broască = 1 * broasc



Caracterul animalic

Nivelul tehnologic

broască = 0.52 * broască + 0.48 * maimuță broască = 0.57 * broască + 0.43 * ușă

broască = 0.52 * [2,2] + 0.48 * [2,3]

broască = 0.57 * [2,2] + 0.43 * [0,4]

Mecanismul de "atentiq

- □ Contextul cuvintel
 - O **broască** s-a în
 - S-a stricat broase

broască = 1 * broască + 0.9 * man broască = 1 * broască + 0.7 * usă

broască = 0.52 * broască + 0.48 * maimuță broască = 0.57 * broască + 0.43 * ușă/

broască = 0.52 * [2,2] + 0.48 * [2,3]

broască = 0.57 * [2,2] + 0.43 * [0,4]

Caracterul animalic

Vivelul tehnologic

Mecanismul de "atentig

- □ Contextul cuvintel
 - O **broască** s-a în
 - S-a stricat broase

```
broască = 0.52 * broască + 0.48 * maimuță
```

broască = 0.57 * broască + 0.43 * ușă

broască =
$$0.52 * [2,2] + 0.48 * [2,3]$$

broască =
$$0.57 * [2,2] + 0.43 * [0,4]$$

broască = [2.00, 2.48]

broască = [1.14, 2.86]

Mecanismul de "atentie" (a

- Contextul cuvintelor -
 - O broască s-a întâlnit
 - S-a stricat **broasca** de

```
broască = 0.52 * broască + 0.48 * maimuță
```

broască = 0.57 * broască + 0.43 * ușå

```
broască = 0.52 * [broască(KQ,KQ)] + 0.48 * [maimuță(KQ,KQ)]
```

Caracterul animalic

broască = 0.57 * [broască(KQ,KQ)] + 0.43 * [ușă(KQ,KQ)]

Mecanismul de "atentie" (2

- Contextul cuvintelor -
 - O broască s-a întâlnit
 - S-a stricat **broasca** de

```
broască = 0.52 * broască + 0.48 * maimuță
```

broască = 0.57 * broască + 0.43 * ușă

```
broască = 0.52 * [broască(KQ,KQ)] + 0.48 * [maimuță(KQ,KQ)]
broască = 0.57 * [broască(KQ,KQ)] + 0.43 * [uṣă(KQ,KQ)]
```

tehnologic

Caracterul animalic

Mecanismul de "atentie" (a)

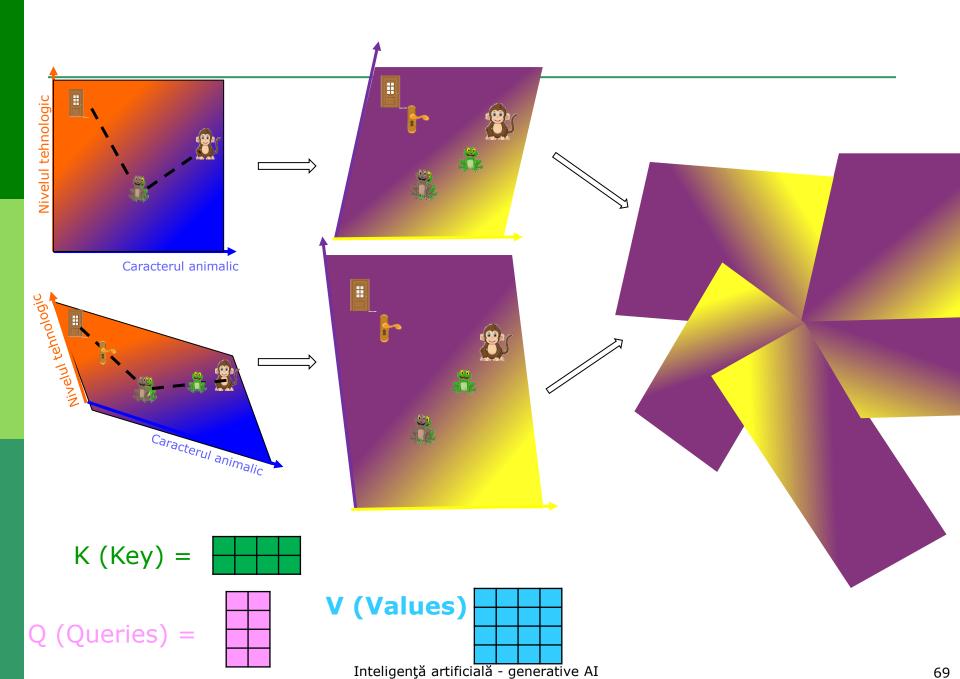
- □ Contextul cuvintelor p
 - O broască s-a întâlnit
 - S-a stricat broasca de

```
broască = 0.52 * broască + 0.48 * maim
```

broască = 0.57 broască + 0.43 * ușă

```
broască \neq 0.52 * [broască(KQ,KQ)] + 0.48 * [maimuță(KQ,KQ)]
```

broască = 0.57 * [broască(KQ,KQ)] + 0.43 * [uṣă(KQ,KQ)]



- Identificarea celor mai bune embedding-uri pentru a stabili similaritatea intre elemente
 - Se bazează pe feature-urile elementelor (e.g. Caracterul animalic, nivelul tehnologic)

- Identificarea celor mai bune embedding-uri pentru a prezice următorul cuvânt
 - Se bazează pe co-apariția elementelor în același context

Input	token1	token2	token3	token4	token5	token6	token7	token8	token9
represent ation	X1								
Queries	q ₁								
Keys	k ₁								
Values	v ₁								
Similariti es	q ₁ • k ₁	q ₁ • k ₂	q ₁ • k ₃	q ₁ • k ₄	q ₁ • k ₅	q ₁ • k ₆	q ₁ • k ₇	q ₁ • k ₈	q ₁ • k ₉
Scores s= [s1, s2,, s9]	q ₁ • k ₁ / √ D	q ₁ • k ₂ / √ D	q ₁ • k ₃ / √ D	q ₁ • k ₄ / √ D	q ₁ • k ₅ / √ D	q ₁ • k ₆ / √ D	q ₁ • k ₇ / √ D	q ₁ • k ₈ / √ D	q ₁ • k ₉ / √ D
w = Softmax(s)									
Weighten ing the values	z ₁ = w ₁ * v ₁ + w ₂ * v ₂ + + w ₉ * v ₉								

Interogari intr-o BD

- Intput:
 - O multime de recorduri { (key_i, value_i), i =1,2, ..., m}
 - Un query q
- Output
 - value_i a.i. q e similar cu key_i
- Exemplu
 - DB = {(Apostol, Mihai), (Baciu, Alina), (Cretu, Gabriel), (Pop, Ionica), (Popa, Madalina), (Popescu, Cosmina)}
 - Query = "Pop"
 - Answer:

Interogari intr-o BD

- Intput:
 - □ O multime de recorduri { (key_i, value_i), i =1,2, ..., m}
 - Un query q
- Output
 - value_j a.i. q e similar cu key_j
- Exemplu
 - DB = {(Apostol, Mihai), (Baciu, Alina), (Cretu, Gabriel), (Pop, Ionica), (Popa, Madalina), (Popescu, Cosmina)}
 - Query = "Pop"
 - Answer:
 - Ionica perfect match (e.g. Hamming Distance)
 - Ionica, Madalina, Cosmina partial match (e.g. Levenshtein Distance), top-k raspunsuri

Q=Pop	Apostol	Baciu	Cretu	Pop	Popa	Popescu
Hamming	6	5	5	0	4	7
Levenshtein	6	5	5	0	1	4

Interogari intr-o baza de date

- Exemplu text
 - □ DB = {(Apostol, Mihai), (Baciu, Alina), (Cretu, Gabriel), (Pop, Ionica), (Popa, Madalina),

(Popescu,	Cosmina)}

Q = "Pop"

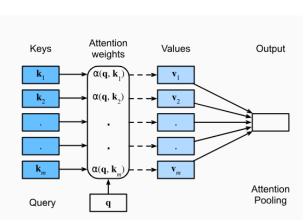
Answer:

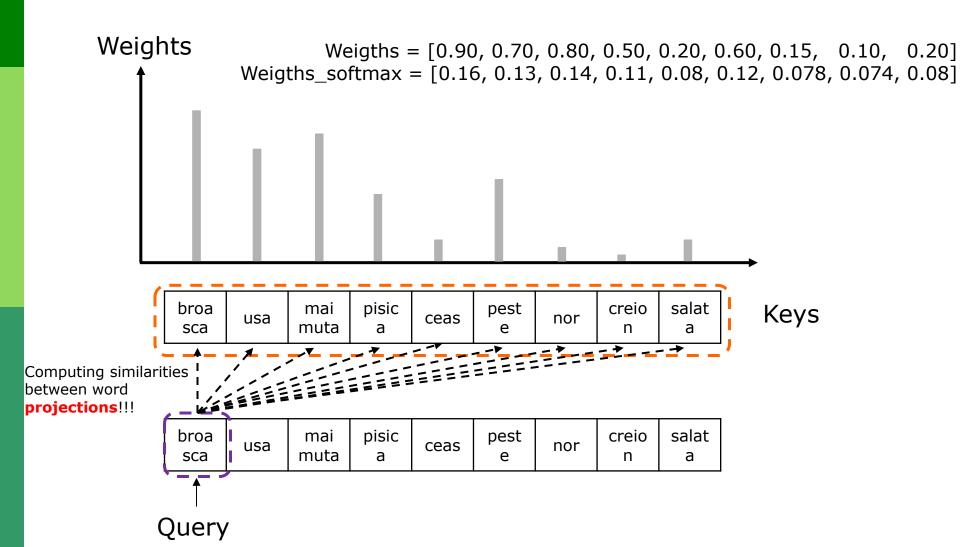
O=Pop	Apostol	Baciu	Cretu	Pop	Popa	Popescu
4 −. οb	Apostoi	Duoid	0.00	. Ор	Гора	. opeseu
Hamming	6	5	5	0	4	7
Levenshtein	6	5	5	0	1	4

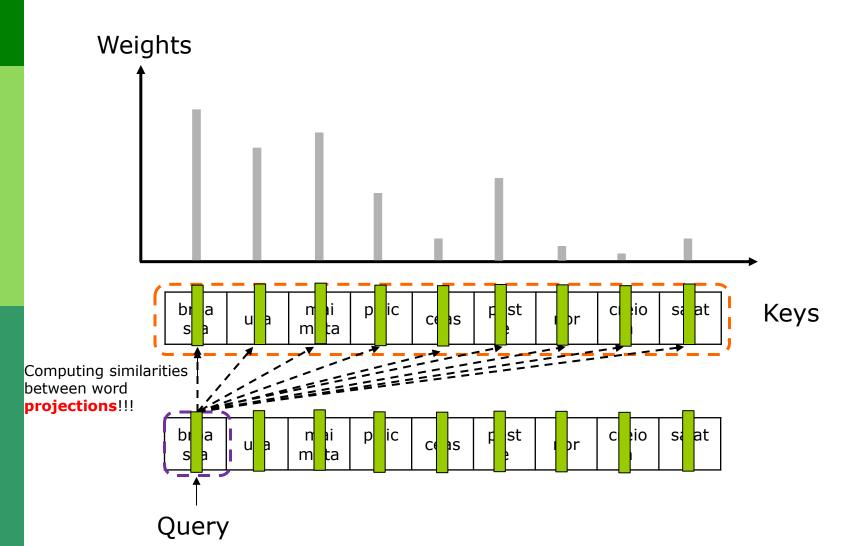
- {Ionica} perfect match (e.g. Hamming Distance)
- {Ionica, Madalina, Cosmina} partial match (e.g. Levenshtein Distance), top-k raspunsuri

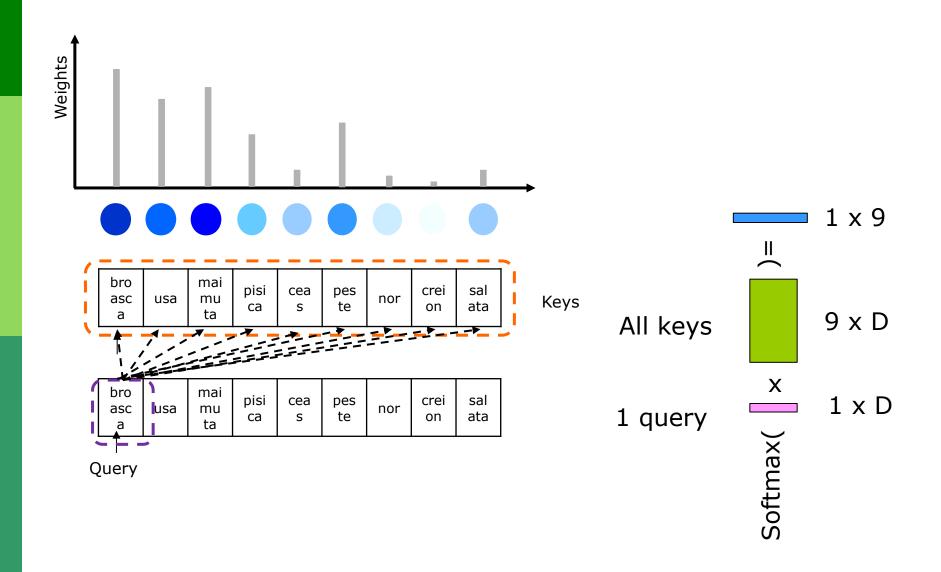
Mecanismul de atentie

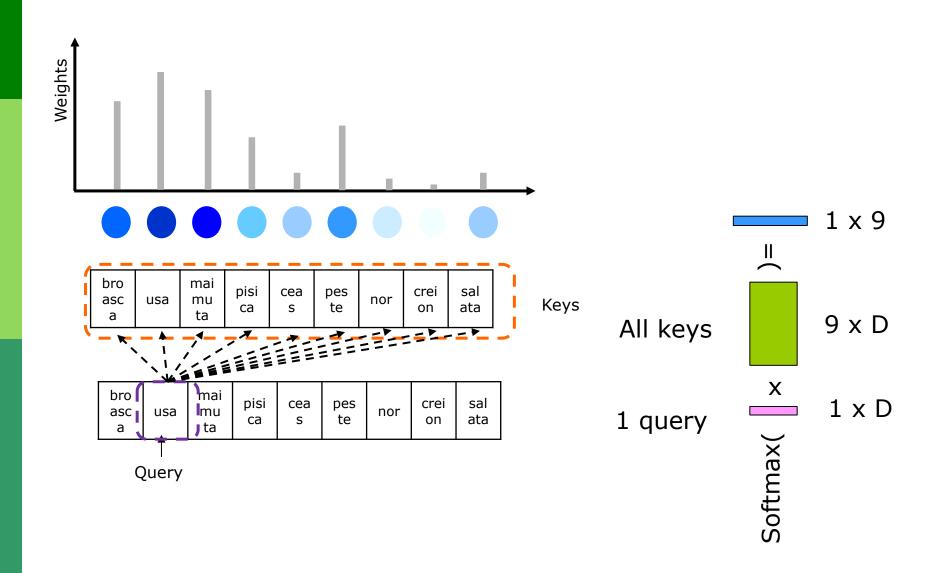
- Attention(q,DB) = $\Sigma \alpha(q, key_i)*value_i$,
 - Query focusul current (query-ul pe care modelul il adreseaza in legatura cu un cuvant/token)
 - Key label-ul sau referinta unui cuvant
 - Value Informatia actuala codata de un cuvant
- $\alpha(q, key_i)$ attention weights
 - Daca un singur coefficient e 1 si restul 0 → interogari
 - Daca toti coeficientii $\alpha = 1/m \rightarrow$ Average Pooling
 - Pentru a avea coeficienti α ca ponderi (weights)
 - $\alpha'(q, key_i) = \alpha(q, key_i) / \Sigma \alpha(q, key_i)$
 - $\alpha'(q, key_i) = exp(\alpha(q, key_i)) / \Sigma exp(\alpha(q, key_i))$

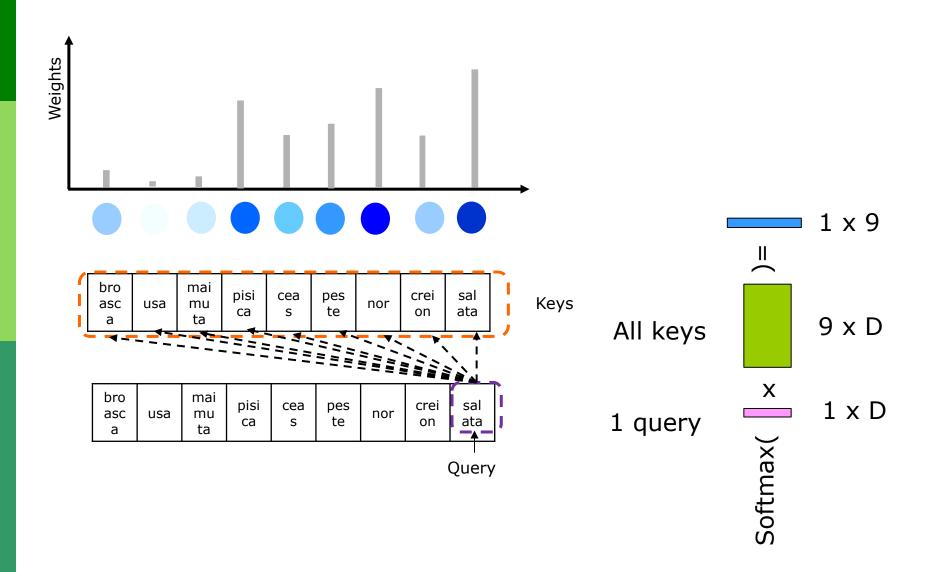


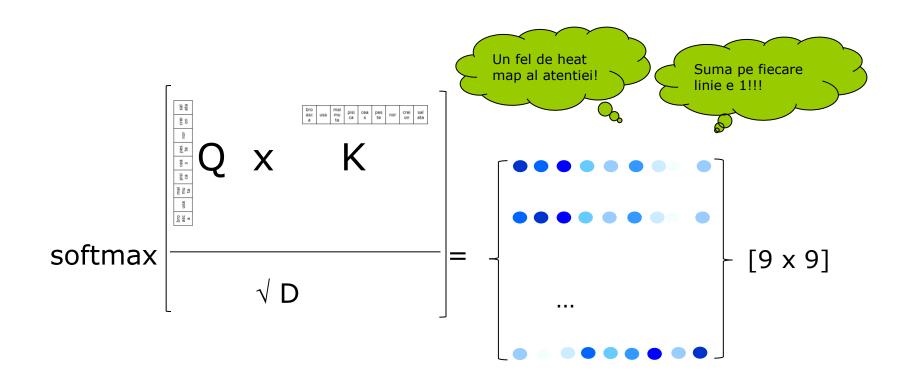


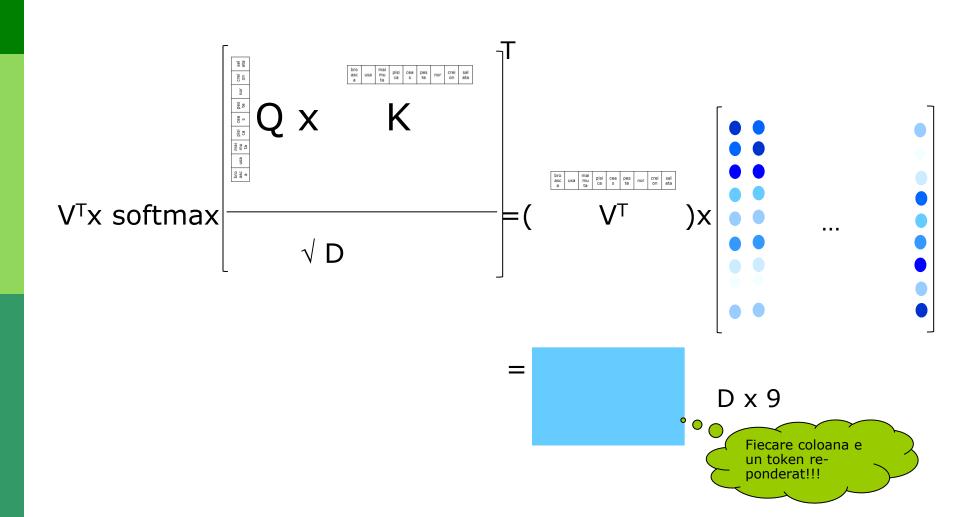


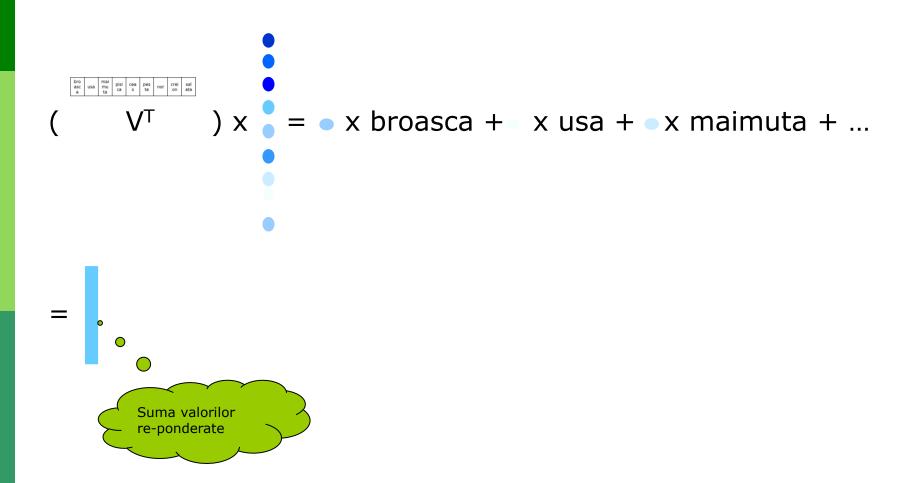












Features

Input = embedding-uri	(de lungime n) pt v cuvinte – matrice v x n
V – matrice v x v	v – nr de cuvinte
K – matrice n x d	n – nr de features (lungimea unui embedding)

\mathbf{x}_1	\mathbf{x}_2	\mathbf{x}_3	X_4
2	0	0	2
0	1	0	0
0	2	1	0
0	0	1	1
2	0	0	0
1	0	1	1
	0 0 0 2	2 0 0 1 0 2 0 0 2 0	2 0 0 0 1 0 0 2 1 0 0 1 2 0 0

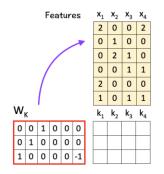
Features

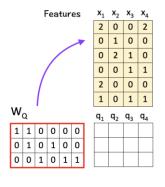
$\mathbf{x_1}$	\mathbf{x}_2	x_3	X_4
2	0	0	2
0	1	0	0
0	2	1	0
0	0	1	1
2	0	0	0
1	0	1	1

- Input = embedding-uri (de lungime n) pt v cuvinte matrice v x n
- V matrice v x v v nr de cuvinte
- K matrice n x d n lungimea reprezentarii dense (embedding)
- Q matrice n x d
 d nr de features abstracte

Transformare

input -> (input x K) x (Q^T x input T) x (V x input) -> features (v,n) -> ((v,n) x (n,d)) x ((d,n) x (n,v)) x ((v,v) x (v,n)) (v,n) -> (v,d) x (d,v) x (v,n)





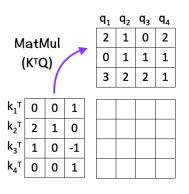
Features

\mathbf{x}_{1}	\mathbf{x}_{2}	\mathbf{x}_3	\mathbf{X}_{4}
2	0	0	2
0	1	0	0
0	2	1	0
0	0	1	1
2	0	0	0
1	0	1	1

- Input = embedding-uri (de lungime n) pt v cuvinte matrice v x n
- V matrice v x v v nr de cuvinte
- K matrice n x d n nr de features (lungimea unui embedding)
- \mathbf{Q} matrice n x d d nr de features abstracte

Transformare

input -> input x K x
$$Q^T$$
 x input^T x V x input -> features
 (v,n) -> $((v,n)$ x (n,d)) x $((d,n)$ x (n,v)) x $((v,v)$ x (v,n))
 (v,n) -> (v,d) x (d,v) x (v,n)
 (v,n) -> (v,v) x (v,n)



Features

\mathbf{x}_{1}	\mathbf{x}_2	\mathbf{x}_3	X_4
2	0	0	2
0	1	0	0
0	2	1	0
0	0	1	1
2	0	0	0
1	0	1	1

- Input = embedding-uri (de lungime n) pt v cuvinte matrice v x n
- V matrice v x v v nr de cuvinte
- K matrice n x d n nr de features (lungimea unui embedding)
- \mathbf{Q} matrice n x d d nr de features àbstracte

Transformare

input -> input x K x
$$Q^T$$
 x input^T x V x input -> features (v,n) -> $((v,n)$ x (n,d)) x $((d,n)$ x (n,v)) x $((v,v)$ x (v,n) (v,n) -> (v,d) x (d,v) x (v,n) (v,n) -> (v,v) x (v,n)

Scalare

input -> input x K x
$$Q^T$$
 x input^T x V x input -> features (v,n) -> $((v,n)$ x (n,d)) x $((d,n)$ x (n,v)) x $((v,v)$ x (v,n)) (v,n) -> (v,d) x (d,v) x (v,n) (v,n) -> (v,v) / \sqrt{d} x (v,n)

Normalizare

input -> input x K x
$$Q^T$$
 x input^T x V x input -> features (v,n) -> $((v,n)$ x (n,d)) x $((d,n)$ x (n,v)) x $((v,v)$ x (v,n) (v,n) -> (v,d) x (d,v) x (v,n) (v,n) -> softmax $((v,v)$ / $\sqrt{d})$ x (v,n)

MatMul

	Input = embeddi	ng-uri (de lungii	me n) pt v cı	uvinte – matrice v x n	1
--	-----------------	-------------------	---------------	------------------------	---

- V matrice v x v v – nr de cuvinte
- K matrice n x d n – nr de features (lungimea unui embedding)
- d nr de features abstracte O – matrice n x d

$\mathbf{x_1}$	\mathbf{x}_{2}	\mathbf{x}_{3}	\mathbf{X}_4
2	0	0	2
0	1	0	0
0	2	1	0
0	0	1	1
2	0	0	0
1	0	1	1

Transformare

input -> input x K x
$$Q^T$$
 x input^T x V x input -> features

$$(v,n) \rightarrow ((v,n) \times (n,d)) \times ((d,n) \times (n,v)) \times ((v,v))$$

$$(v,n) \rightarrow ((v,n) \times (n,v)) \times ((v,n) \times (v,n) \times ($$

$$(v n) \rightarrow (v v)$$

$$(v,n) \rightarrow (v,v)$$
 x

(v,n)'(v,n) ->

S_{C2}	lara	
Sca	ıaı c	

input -> input x K x
$$Q^T$$
 x input^T x V x input -> fe

$$(v,n) \rightarrow ((v,n) \times (n,d)) \times ((d,n) \times (n,v)) \times ((v,v))$$

$$(v,n) \rightarrow (v,d) x (d,v) x$$

$$(v,n) \rightarrow (v,v) / \sqrt{v}$$
 x

$(v,n) \rightarrow (v,n)'$	• •	• • •	
	(v,n) ->		(v,n)'



10	0	0	0	0	0
0	0	0	10	0	0
0	10	0	0	0	0

	$\mathbf{v_1}$	v_2	V_3	V_4
•	20	0	0	20

•	20	0	0	20
•	0	0	10	10
•	0	10	0	0

.3	.3	.4	.1	
.9	.3	.2	.7	
.1	.1	0	.1	
.3	.3	.4	.1	

Attention Weight Matrix (A)

 Z_1 Z_2 Z_3 Z_4

	Attention
	Weighted
	Features

Normalizare

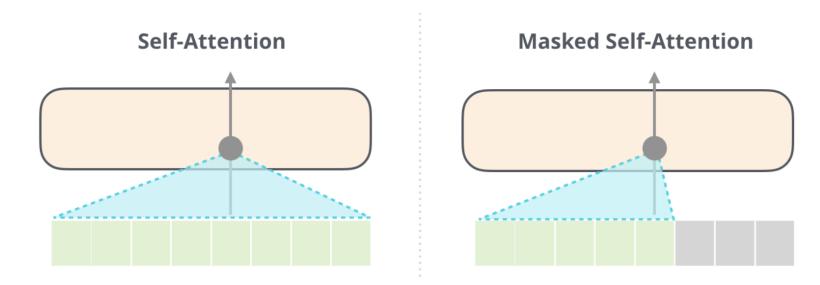
input -> input x K x
$$Q^T$$
 x input T x V x input -> features

$$(v,n) \rightarrow ((v,n) \times (n,d)) \times ((d,n) \times (n,v)) \times ((v,v) \times (v,n))$$

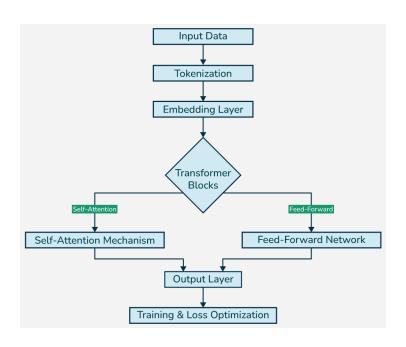
$$(v,n) \rightarrow (v,d) x (d,v) x (v,n)$$

$$(v,n) \rightarrow softmax((v,v) / \sqrt{v}) x (v,n)$$

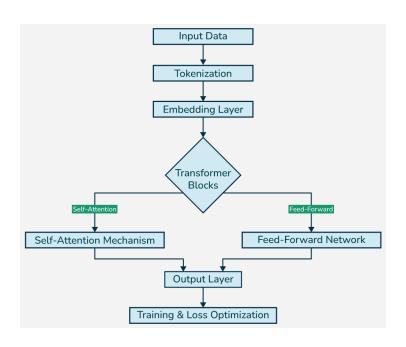
$$(v,n) \rightarrow (v,n)$$



- □ Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network



- Large language Models (LLMs)
 - Tokenisation
 - Embeddings
 - Transformer & Self-attention mechanism
 - Feed-forward network
 - Normalisation layers
 - Softmax layers
 - Loss functions



```
Large language Models (LLMs)
                                                                                                                                    Forward
            How large an LLM is?
                 |Vocabular| = V
                                                                                                                                  Add & Norm
                                                                                                                   Add & Norm
                        Words/tokens
                                                                                                                                    Multi-Head
                   |Embedding| = E (model dimension)
                                                                                                                      Feed
                                                                                                                                    Attention
                                                                                                                     Forward
                                                                                                                                                 N×
                   |input sequence| = L (context window)
                                                                                                                                  Add & Norm
                   No of blocks NB
                                                                                                          N \times
                                                                                                                   Add & Norm
                   Size of MLP's hidden layers H
                                                                                                                                    Masked
                                                                                                                    Multi-Head
                                                                                                                                    Multi-Head
                                                                                                                    Attention
                                                                                                                                    Attention
GPT2Model(
               TokenEmbedding,
                                                \rightarrow V x \not\vdash param
               PositionalEMbedding,
                                                \rightarrow \cancel{\bot}x E param
                                                                                                         Positional
                                                                                                                                              Positional
               Dropout,
                                                                                                         Encodina
                                                                                                                                              Encoding
               NB x TransformerBlock(
                                                                                                                     Input
                                                                                                                   Embeddina
                                                                                                                                   Embeddina
                   Normalisation,
                                                \rightarrow 2 x E
                                                \rightarrow 3 x (E x E + E) + E x E + E
                   MSA,
                                                                                                                     Inputs
                                                                                                                                    Outputs
                   Normalisation,
                                                                                                                                  (shifted right)
                   MLP(
                                                \rightarrow E x H + H
                       Linear,
                                                \rightarrow HXE+E
                       Linear,
               Normalisation,
                                                → 2E
                                                \rightarrow E X V
               Linear
                                                                                                                                       param(others)
                                                                                 param(transformer)
                     param(embeddings)
#param
                                                     +
                 (WTextEmb + WPosEmb)
                                                                       NB * (Norm + Attn + Norm + MLP)
                                                                                                                                       Norm + Linear
                                                           NB * (2E + (3 * (E \times E + E) + (E \times E + E)) + 2E + (E \times E))
                        (V \times E + L \times E)
                                                                                                                                         2E + E \times V
                                                                                H + H + H \times E + E)
                                                   E \times (V + L) + NB \times (4E^2 + 9E + 2EH + H) + 2E + E \times V
                                                    Inteligență artificială - generative AI
```

Output
Probabilities

Softmax

Linear

Add & Norm

- Large language Models (LLMs)
 - How large an LLM is?
 - □ |Vocabular| = V
 - Words/tokens
 - | | Embedding | = E (model dimension)
 - | input sequence| = L (context window)
 - No of blocks NB
 - Size of MLP's hidden layers H

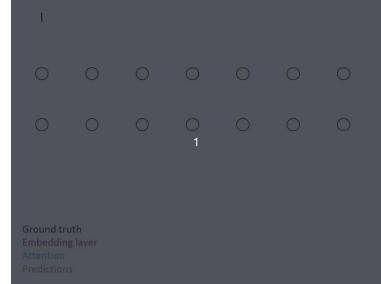
$$\#$$
param = E x (V + L) + NB x (4E² + 9E + 2EH + H) + 2E + E x V

	V	E	L	NB	н	#param
GPT2	50 257	768	1 024	12	3 072	124 439 808
GPT3	50 257	12 288	2 048	96	12 288	87 627 632 640

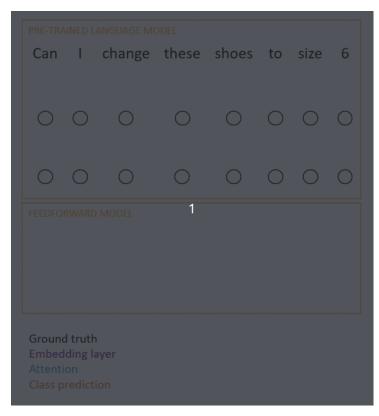
- Architecture
- Pre-training unsupervised
- Masked language modelling



Next word prediction (causal language modeling)

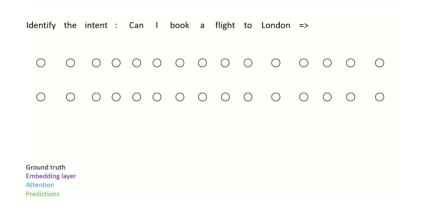


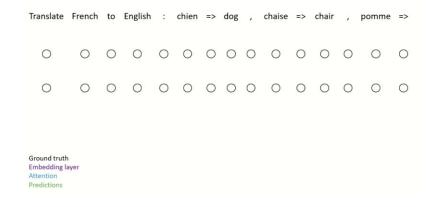
- Architecture
- Pre-training unsupervised
- Fine-tunning
 - Specific task
 - Another model -> Additional layers (params)



- Architecture
- Pre-training unsupervised
- Fine-tunning
- Prompt-based learning
 - Simple

With examples (k-shot learning)





Transformers - roadmap

Resources

- https://jalammar.github.io/illustrated-transformer/
- <u>Transformers</u> (how LLMs work) explained visually | DL5 YouTube https://www.youtube.com/watch?v=wjZofJX0v4M
- <u>LLM Visualization https://bbycroft.net/llm</u>
- nanoGPT https://www.youtube.com/watch?v=kCc8FmEb1nY
- Attention https://lilianweng.github.io/posts/2018-06-24-attention/
- https://arxiv.org/pdf/1706.03762
- https://github.com/karpathy/nanoGPT
- https://github.com/karpathy/ng-video-lecture
- https://colab.research.google.com/drive/1JMLa53HDuAi7ZBmqV7ZnA3c fvtXnx-?usp=sharing
- https://paperswithcode.com/paper/attention-is-all-youneed
- https://www.youtube.com/watch?v=kCc8FmEb1nY

Cursul următor

A. Scurtă introducere în Inteligența Artificială (IA)

B. Sisteme inteligente

- Sisteme care învaţă singure
 - Arbori de decizie
 - Retele neuronale artificiale transformers
 - Maşini cu suport vectorial
 - Algoritmi evolutivi
- Sisteme bazate pe reguli
- Sisteme hibride

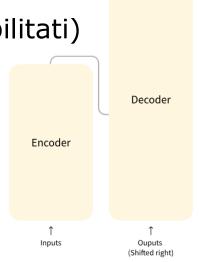
C. Rezolvarea problemelor prin căutare

- Definirea problemelor de căutare
- Strategii de căutare
 - Strategii de căutare neinformate
 - Strategii de căutare informate
 - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
 - Strategii de căutare adversială

- Informaţiile prezentate au fost colectate din diferite surse de pe internet, precum şi din cursurile de inteligenţă artificială ţinute în anii anteriori de către:
 - Conf. Dr. Mihai Oltean <u>www.cs.ubbcluj.ro/~moltean</u>
 - Lect. Dr. Crina Groşan <u>www.cs.ubbcluj.ro/~cgrosan</u>
 - Prof. Dr. Horia F. Pop <u>www.cs.ubbcluj.ro/~hfpop</u>
 - Prof. Dr. Radu Ionescu https://raduionescu.herokuapp.com/

Architecture

- Encoder
 - Primeste cuvinte
 - Construieste reprezentari (features) ale cuvintelor
- Decoder
 - Primeste
 - reprezentari (features) ale cuvintelor
 - Alte inputuri
 - Genereaza secvente de cuvinte (ca probabilitati)



Output probabilities

Decoder Encoder † † † Ouputs (Shifter ignt)

Arhitectura

- Modele bazate doar pe encoder
 - Proiectate pentru a invata sa prezica output-uri specifice unui task
 - In: texte
 - Out: labels sau tokens
 - Task-uri pe care le pot rezolva
 - Clasificare de propozitii
 - Identificarea in texte a unor sentimente/emotii
 - Ex. BERT, RoBERTa
- Modele bazate doar pe decoder
 - Proiectate pentru a genera noi texte (decoding realizat in stil auto-regresiv = generare de secvente, token by token, fiecare token fiind conditionat de token-urile anterior generate)
 - In: embeddings
 - Out: texte
 - Task-uri pe care le pot rezolva
 - Raspuns la diferite queries
 - Ex. GPT
- Modele bazate pe encoder-decoder
 - Proiectate pentru a genera noi texte
 - In: texte
 - Out: texte
 - Task-uri pe care le pot rezolva
 - rezumat de texte
 - Traducere de texte
 - Ex. BART, T5

Encoder-only

- Proiectata sa inteleaga textul de intrare si sa genereze reprezentari fixe ale textului dat ca input
- Mecanism de atentie bidirectional (un token e "atent" la toti ceilalti tokeni sin textul de intrare)
- Decoder-only (causal decoder architecture)
 - Proiectata sa genereze texte (predictia urmatorului token intr-o anumita secventa)
 - Mecanism de atentie unidirectional (un token e "atent" doar la tokenii care il preced si la el insusi)

Encoder-decoder

- Proiectata sa inteleaga textul de intrare si sa genereze text de output
- Mecanism de atentie
 - Bidirectional in encoder
 - Unidirectional in decoder

Encoder-decoder

Encoder

Map input sequence into latent representation by some multi-head self-attention layers

Decoder

 Performs cross-attention on latent representations to generate target sequence

- GitHub mlabonne/llm-course: Course to get into Large Language Models (LLMs) with roadmaps and Colab notebooks.
- Attention? Attention! | Lil'Log