UNIVERSITATEA BABEŞ-BOLYAI
Facultatea de Matematică şi Informatică

INTELIGENȚĂ ARTIFICIALĂ

Sisteme inteligente

Sisteme care învaţă singure

Laura Dioşan

Sumar

A. Scurtă introducere în Inteligenţa Artificială (IA)

B. Sisteme inteligente

- Sisteme care învaţă singure
  - Metoda celor mai mici patrate, Gradient Descent, Logistic regression
  - Arbori de decizie
  - Reţele neuronale artificiale
  - Maşini cu suport vectorial
  - Algoritmi evolutivi
- Sisteme bazate pe reguli
- Sisteme hibride

A. Rezolvarea problemelor prin căutare

- Definirea problemelor de căutare
- Strategii de căutare
  - Strategii de căutare neinformate
  - Strategii de căutare informate
  - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
  - Strategii de căutare adversială

Materiale de citit şi legături utile

- capitolul VI (18) din *S. Russell, P. Norvig, Artificial Intelligence: A Modern Approach, Prentice Hall, 1995*
- capitolul 10 şi 11 din *C. Groşan, A. Abraham, Intelligent Systems: A Modern Approach, Springer, 2011*
- capitolul V din *D. J. C. MacKey, Information Theory, Inference and Learning Algorithms, Cambridge University Press, 2003*
- capitolul 3 din *T. M. Mitchell, Machine Learning, McGraw-Hill Science, 1997*

Conținut

- Sisteme inteligente
  - Sisteme care învaţă singure (SIS)
    - Instruire (învăţare) automata (Machine Learning - ML)
      - Problematică
      - Proiectarea unui sistem de învăţare automată
      - Tipologie
        - Învăţare supervizată
        - Învăţare nesupervizată
        - Învăţare cu întărire
        - Teoria învăţării
    - Exemple de sisteme

Conținut

- Sisteme care învaţă singure (SIS)

  - "Field of study that gives computers the ability to learn without being explicitly programmed." -- Arthur Samuels (1959)

- Invățare
  - Supervizată
  - Nesupervizată
  - Reinforcement

Sisteme inteligente – SIS – Învățare automată

- Framework pentru regresii liniare

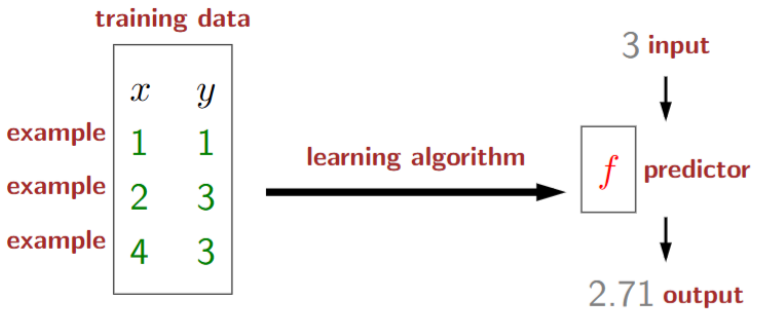

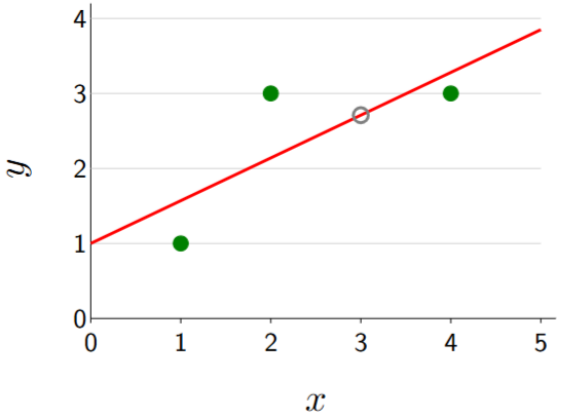

- Proiectarea deciziilor
  - Ce fel de modele de predictie sunt posibile?
  - Cat de bun este un model de predictive?
  - Cum se poate identifica cel mai bun predictor?

Sisteme inteligente – SIS – Învățare automată

- Framework pentru regresii liniare

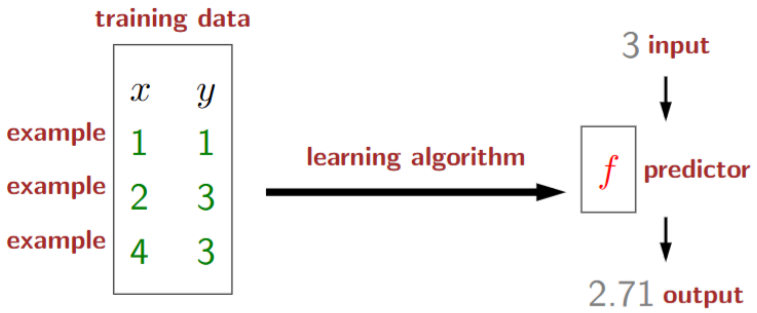

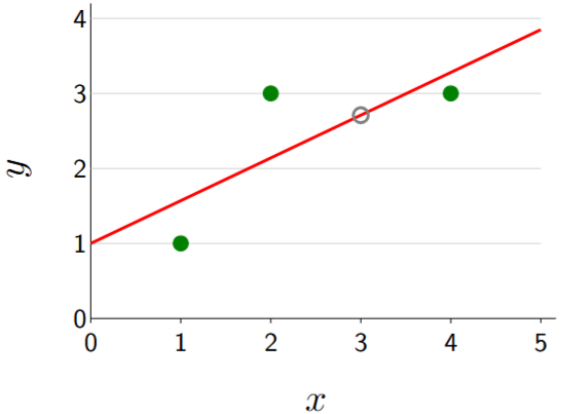

- Proiectarea deciziilor
  - Ce fel de modele de predictie sunt posibile?
    - Ipotezele care se valideaza
  - Cat de bun este un model de predictie?
    - Functia de cost
  - Cum se poate identifica cel mai bun predictor?
    - Algoritmul de optimizare

Sisteme inteligente – SIS – Învățare automată

- Framework pentru regresii liniare → ipoteze

$$f(x) = 1 + 0.57x$$

$$f(x) = 2 + 0.2x$$

$$f(x) = w_1 + w_2 x$$

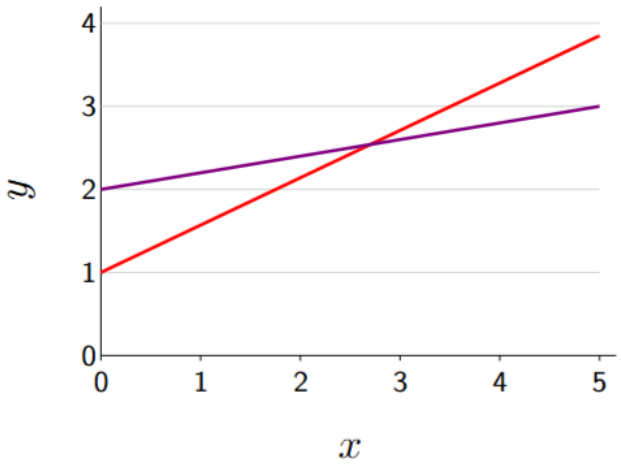

weight vector $\mathbf{w} = [w_1, w_2]$

feature extractor $\phi(x) = [1, x]$ feature vector

$$f_{\mathbf{w}}(x) = \mathbf{w} \cdot \phi(x)$$ score

$$f_{\mathbf{w}}(3) = [1, 0.57] \cdot [1, 3] = 2.71$$

Sisteme inteligente – SIS – Învățare automată

- Framework pentru regresii liniare → calitatea unui model de predictie

$$f_{\mathbf{w}}(x) = \mathbf{w} \cdot \phi(x)$$
$$\mathbf{w} = [1, 0.57]$$
$$\phi(x) = [1, x]$$

training data $\mathcal{D}_{\text{train}}$

x	y
1	1
2	3
4	3

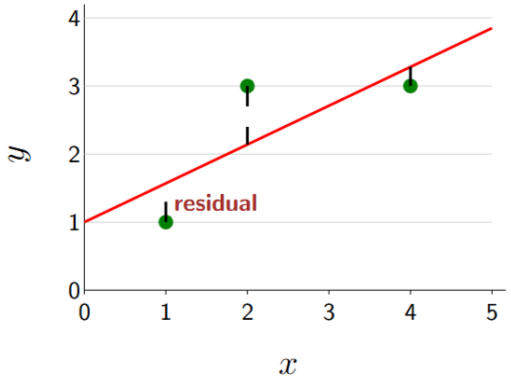

$$\text{Loss}(x, y, \mathbf{w}) = (f_{\mathbf{w}}(x) - y)^2$$

$$\text{Loss}(1, 1, [1, 0.57]) = ([1, 0.57] \cdot [1, 1] - 1)^2 = 0.32$$
$$\text{Loss}(2, 3, [1, 0.57]) = ([1, 0.57] \cdot [1, 2] - 3)^2 = 0.74$$
$$\text{Loss}(4, 3, [1, 0.57]) = ([1, 0.57] \cdot [1, 4] - 3)^2 = 0.08$$

$$\text{TrainLoss}(\mathbf{w}) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} \text{Loss}(x, y, \mathbf{w})$$

$$\text{TrainLoss}([1, 0.57]) = 0.38$$

Sisteme inteligente – SIS – Învățare automată

- Framework pentru regresii liniare → cel mai bun model de predictie?
  - Metoda celor mai mici patrate
  - Metoda gradientului

Sisteme inteligente – SIS – Învățare automată

- Metoda celor mai mici pătrate
  - Presupunem cazul unei probleme de regresie
    - Date de intrare $x \in R^d$
    - Date de ieșire $y \in R$

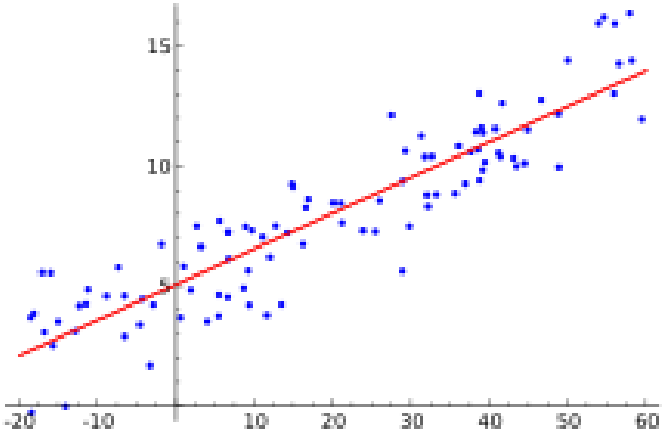

    - Se cere un model **liniar** f care transformă x în y
    - $f(x) = w_0 + w_1x_1 + w_2x_2 + ... + w_dx_d$
    - Invățare supervizată

Sisteme inteligente – SIS – Învățare automată

- Metoda celor mai mici pătrate
  - Presupunem cazul unei probleme de regresie
    - Date de intrare $x^i \in R^d$, i=1,n
    - Date de ieșire $y^i \in R$
    - Se cere un model **liniar** f care transformă orice x^i în y^i , i=1,n
    - $f(x) = w_0 + w_1x_1 + w_2x_2 + \ldots + w_dx_d$

    - Se poate defini o funcție de cost
    - Loss = $\sum_{i=1,n} (y^i - f(x^i))^2$ -- minimizată ➔ valorile optime ale lui w

$\mathbf{x} = (1, x) = (1, x_1, x_2, \ldots, x_d)^T \in R^{d+1}$
$\mathbf{w} = (w_0, w_1, w_2, \ldots , w_d)^T \in R^{d+1}$
$f(\mathbf{x}) = \mathbf{x}^T \mathbf{w}$
$\text{Loss}(\mathbf{w}) = \| y - \mathbf{X}\, w \|^2$

$$X = \begin{matrix} 1 & x_{1,1} & x_{1,2} & x_{1,3} & \ldots & x_{1,d} \\ . \\ . \\ . \\ 1 & x_{n,1} & x_{n,2} & x_{n,3} & \ldots & x_{n,d} \end{matrix}$$

Sisteme inteligente – SIS – Învățare automată

- Metoda celor mai mici pătrate
  - Presupunem cazul unei probleme de regresie
    - Date de intrare $x^i \in R^d$, i=1,n
    - Date de ieșire $y^i \in R$
    - Se cere un model **liniar** f care transformă orice x^i în y^i , i=1,n
    - $f(x) = w_0 + w_1x_1 + w_2x_2 + ... + w_dx_d$
    - Se poate defini o funcție de cost
    - Loss = $\sum_{i=1,n} (y^i - f(x^i))^2$ -- minimizată ➔ valorile optime ale lui w
    - $w = (X^TX)^{-1}X^Ty$
    - Daca d = 1, $w_1 = cov(x,y)/var(x)$, $w_0 = y - w_1 x$

Sisteme inteligente – SIS – Învățare automată

- Metoda *gradient descent*
  - Presupunem cazul unei probleme de regresie
    - Date de intrare $x \in R^d$
    - Date de ieșire $y \in R$

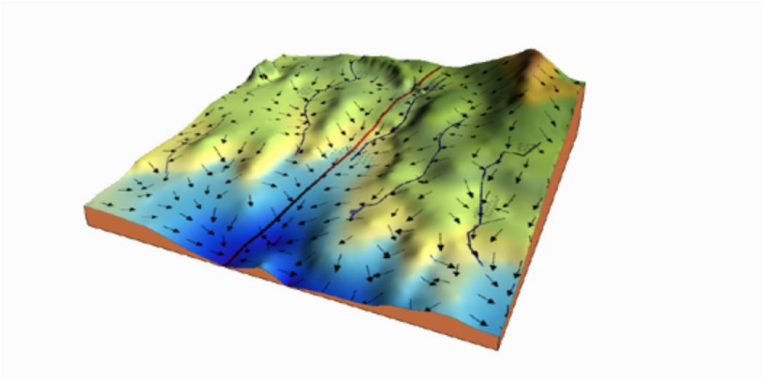

    - Se cere un model **liniar** f care transformă x în y
    - $f(x) = w_0 + w_1x_1 + w_2x_2 + ... + w_dx_d$
    - Invățare supervizată – aflarea valorilor w pentru care eroarea este optima (minima) → Derivarea loss-ului după w

Ref. imagine

Sisteme inteligente – SIS – Învățare automată

- Metoda *gradient descent*

  Goal: $\min_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$

  - *Defintie gradient al loss-ului – directia care modifica loss-ul cel mai mult*

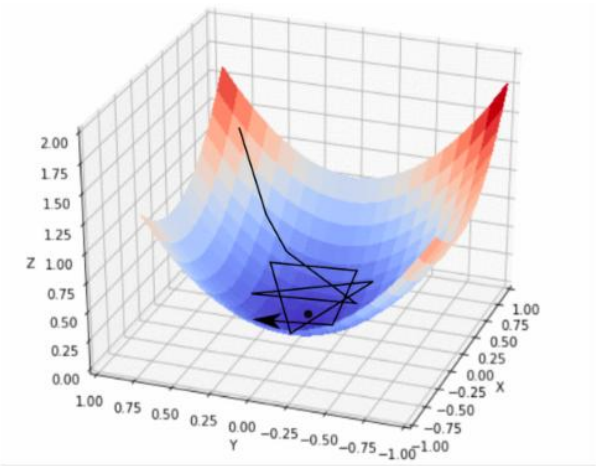

Algorithm: gradient descent

Initialize $\mathbf{w} = [0, \ldots, 0]$

For $t = 1, \ldots, T$: **epochs**

$$\mathbf{w} \leftarrow \mathbf{w} - \underbrace{\eta}_{\text{step size}} \underbrace{\nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})}_{\text{gradient}}$$

Ref. imagine

- Metoda *gradient descent*

  Goal: $\min_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$

  - *Calcul gradient*

    Objective function:

$$\text{TrainLoss}(\mathbf{w}) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y)\in\mathcal{D}_{\text{train}}} (\mathbf{w}\cdot\phi(x) - y)^2$$

    Gradient (use chain rule):

$$\nabla_{\mathbf{w}}\text{TrainLoss}(\mathbf{w}) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y)\in\mathcal{D}_{\text{train}}} 2(\underbrace{\mathbf{w}\cdot\phi(x) - y}_{\text{prediction}-\text{target}})\phi(x)$$

Sisteme inteligente – SIS – Învățare automată

- Metoda *gradient descent*
  - Modelarea coeficienților w:
    - la iterația 0: valori random (sau 0)
    - la iterația t + 1 (t = 1, 2, …)

    $w_k(t+1) = w_k(t)$ - learning_rate * error(t) * x_k, k=1,2,...,d

    $w_0(t+1) = w_0(t)$ - learning_rate * error(t)
      - Unde
        - error(t) = computed - realOutput
        - error(t) = $w_0(t) + w_1(t)*x_1 + w_2(t)*x_2 + \ldots + w_d(t)*x_d - y$

Sisteme inteligente – SIS – Învățare automată

- Metoda *gradient descent* – versiuni:
  - GD
    - Eroarea se calculează pentru toate exemplele de antrenament
    - Modelul se updatează dupa ce toate exemplele de antrenament au fost evaluate (la finalul unei epoci)

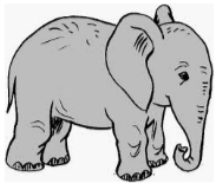

Algorithm: gradient descent

Initialize $\mathbf{w} = [0, \ldots, 0]$
For $t = 1, \ldots, T$:
$\quad \mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} \text{TrainLoss}(\mathbf{w})$

  - Stochastic GD
    - Eroarea se calculează pentru fiecare exemplu de antrenament
    - Modelul se updatează pentru fiecare exemplu de antrenament (*online learning*)

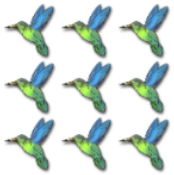

Algorithm: stochastic gradient descent

Initialize $\mathbf{w} = [0, \ldots, 0]$
For $t = 1, \ldots, T$:
$\quad$ For $(x, y) \in \mathcal{D}_{\text{train}}$:
$\quad\quad \mathbf{w} \leftarrow \mathbf{w} - \eta \nabla_{\mathbf{w}} \text{Loss}(x, y, \mathbf{w})$

Sisteme inteligente – SIS – Învățare automată

- Metoda *gradient descent* – versiuni:
  - GD
    - Eroarea se calculează pentru toate exemplele de antrenament
    - Modelul se updatează dupa ce toate exemplele de antrenament au fost evaluate (la finalul unei epoci)
  - Stochastic GD
    - Eroarea se calculează pentru fiecare exemplu de antrenament
    - Modelul se updatează pentru fiecare exemplu de antrenament (*online learning*)
  - Mini-batch GD
    - Combinare a precedentelor două
    - Setul de date se împarte în mai multe părți (mini-batch-uri)
    - Eroarea se calculează pentru fiecare exemplu de antrenament dintr-un mini-batch
    - Modelul se updatează pentru fiecare exemplele din mini-batch

Sisteme inteligente – SIS – Învățare automată

- Regresie Logistică (clasificare)
  - Presupunem cazul unei probleme de clasificare
    - Date de intrare $x^i \in R^d$, i=1,n
    - Date de ieșire $y^i \in \{0,1\}$ sau {label1, label2}

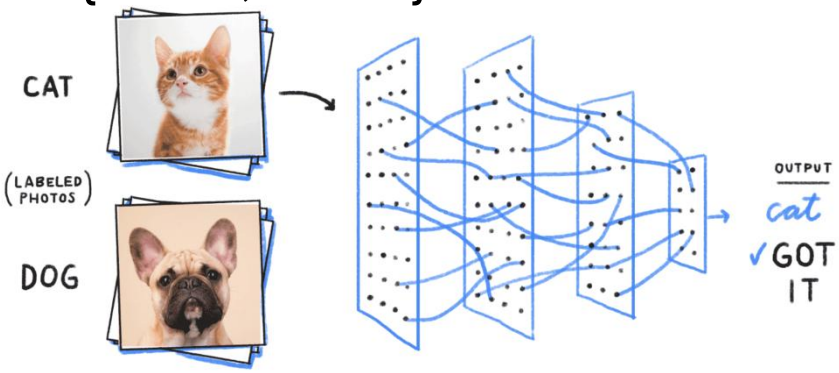

    - Se cere un model **liniar** f care separa orice x^i în 2 clase (etichetate cu 0 și 1)
    - $f(x) = w_0 + w_1x_1 + w_2x_2 + ... + w_dx_d$
    - Invățare supervizată

Sisteme inteligente – SIS – Învățare automată

- Regresie Logistică (clasificare)
  - Mapează datele intr-un set discret de clase (label-uri)
  - Tipuri:
    - Binar (Pass/Fail, True/False)
    - Multi (Cat,Dog,Panda)
    - Ordinal (Low,Medium,High)
  - Folosește funcția sigmoid pentru a decide clasa de apartentență
  - Putem folosi gradient descent pentru minimzarea erorii

Sisteme inteligente – SIS – Învățare automată

- Regresie Logistică – sigmoid:
  - Mapează orice numar real in intervalul (0,1)

$$S(z) = \frac{1}{1 + e^{-z}}$$

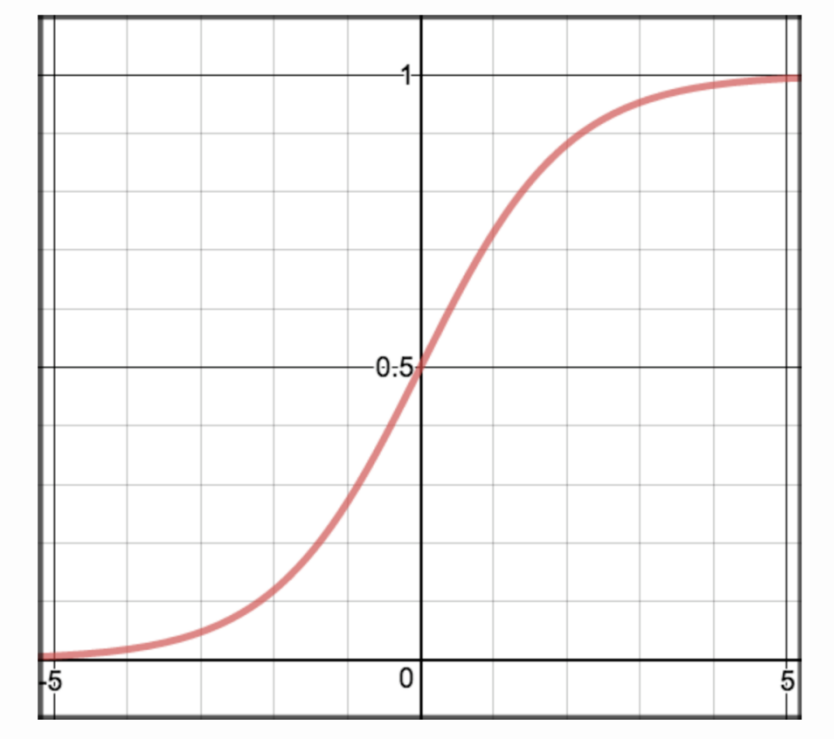

Ref. imagine

Sisteme inteligente – SIS – Învățare automată

- Regresie Logistica
  - Modelarea coeficienților w:
    - la iterația 0: valori random (sau 0)
    - la iterația t + 1 (t = 0, 1, 2, …)

    $w_k(t+1) = w_k(t) - learning_rate * error(t) * x_k$, $k=1,2,...,d$

    $w_0(t+1) = w_0(t) - learning_rate * error(t)$
      - Unde
        - error(t) = Sigmoid(computed) - realOutput
        - $error(t) = Sigmoid(w_0(t) + w_1(t)*x_1 + w_2(t)*x_2 + ... + w_d(t)*x_d) - y$
  - Clasificarea rezultatelor
    - (0,1) -> [$label_0$, $label_1$, .. $label_n$]

Recapitulare

- Sisteme care învaţă singure (SIS)
  - Instruire (învăţare) automata (Machine Learning - ML)
    - Învăţare supervizată → datele de antrenament sunt deja etichetate cu elemente din E, iar datele de test trebuie etichetate cu una dintre etichetele din E pe baza unui model (învăţat pe datele de antrenament) care face corespondenţa date-etichete
    - Învăţare nesupervizată → datele de antrenament NU sunt etichetate, trebuie învăţat un model de etichetare, iar apoi datele de test trebuie etichetate cu una dintre etichetele identificate de model

Recapitulare

- Sisteme care învaţă singure (SIS)
  - Metoda celor mai mici patrate
    - Supervizată
    - Output continu (vânzări, preț, etc.)
    - Panta constantă
  - Gradient descent
    - Supervizată
    - Output continu (vânzări, preț, etc.)
    - Optimizare
  - Regresie Logistică
    - CLASIFICARE
    - Supervizată
    - Output – label-uri (clase) – set discret
    - Folosește Gradient descent

Cursul următor

A. Scurtă introducere în Inteligenţa Artificială (IA)

B. Sisteme inteligente

- Sisteme care învaţă singure
  - Arbori de decizie
  - Reţele neuronale artificiale
  - Maşini cu suport vectorial
  - Algoritmi evolutivi
- Sisteme bazate pe reguli
- Sisteme hibride

C. Rezolvarea problemelor prin căutare

- Definirea problemelor de căutare
- Strategii de căutare
  - Strategii de căutare neinformate
  - Strategii de căutare informate
  - Strategii de căutare locale (Hill Climbing, Simulated Annealing, Tabu Search, Algoritmi evolutivi, PSO, ACO)
  - Strategii de căutare adversială

Cursul următor – Materiale de citit şi legături utile

- Capitolul VI (19) din *S. Russell, P. Norvig, Artificial Intelligence: A Modern Approach, Prentice Hall, 1995*
- capitolul 8 din *Adrian A. Hopgood, Intelligent Systems for Engineers and Scientists, CRC Press, 2001*
- capitolul 12 şi 13 din *C. Groşan, A. Abraham, Intelligent Systems: A Modern Approach, Springer, 2011*
- Capitolul V din *D. J. C. MacKey, Information Theory, Inference and Learning Algorithms, Cambridge University Press, 2003*
- Capitolul 4 din *T. M. Mitchell, Machine Learning, McGraw-Hill Science, 1997*

- Informaţiile prezentate au fost colectate din diferite surse de pe internet, precum şi din cursurile de inteligenţă artificială ţinute în anii anteriori de către:
  - Conf. Dr. Mihai Oltean – www.cs.ubbcluj.ro/~moltean
  - Lect. Dr. Crina Groşan - www.cs.ubbcluj.ro/~cgrosan
  - Prof. Dr. Horia F. Pop - www.cs.ubbcluj.ro/~hfpop